

دانشگاه اصفهان

دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی

رشته مهندسی کامپیوتر گرایش هوش مصنوعی

توسعه دستیار پزشکی فارسی مبتنی بر مدلهای زبانی بزرگ

Persian Medical Assistant Development Based on Large Language Models

استاد راهنما:
دکتر حمیدرضا برادران

پژوهشگر:
سیدمحمدحسین هاشمی

اردیبهشت ۱۴۰۴


بسم الله الرحمن الرحيم



دانشگاه اصفهان

دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی

رشته مهندسی کامپیوتر گرایش هوش مصنوعی

توسعه دستیار پزشکی فارسی مبتنی بر مدلهای زبانی بزرگ

Persian Medical Assistant Development Based on Large Language Models

استاد راهنما:
دکتر حمیدرضا برادران

پژوهشگر:
سیدمحمدحسین هاشمی

اردیبهشت ۱۴۰۴

چکیده

با معرفس مدل‌های زبانی بزرگ مانند ChatGPT که در بسیاری از حوزه‌های علمی دانش خوبی دارند به مرور نیاز به مدل‌های متخصص نیز ایجاد شد. علاوه بر این مدل‌هایی از این قبیل دو مشکل اساسی دارند که به آن می‌پردازیم.

یکی از بزرگ‌ترین مشکلات این مدل‌ها این است که تضمینی برای اینکه سوالات و داده‌های ارسالی را ذخیره نکنند وجود ندارد. در داده‌هایی مانند داده‌های پزشکی که حساسیت بسیار بالایی دارد این اتفاق پیامدهای بسیار بدی می‌تواند داشته باشد.

دومین مشکل، مشکل وزن مدل‌هاست، ما نیاز داریم مدل‌ها را در سخت افزارهایی بسیار محدودتر از OpenAI و سایر شرکت‌های این حوزه اجرا کنیم، چون همانطور که اشاره شد برای اینکه اطلاعات در سیستم‌های خارجی ذخیره نشود نیاز است که مدل‌ها در سخت افزارهای محلی و ضعیف هم به خوبی کار کند.

با توجه به مشکلات اشاره شده هدف این پروژه توسعه مدل متخصص پزشکی است که در آن دانش داخلی و خارجی مدل ارتقا داده می‌شود و از تکنیک‌های Prompt engineering نیز برای افزایش دقت پاسخدهی استفاده می‌کنیم.

فهرست مطالب

۱ مقدمه ۱

۲ پژوهش‌های مشابه ۳
۱.۲ Med-PaLM ۳
۲.۲ Meditron ۳
۳.۲ BioMistral ۴
۴.۲ Aloe ۴
۵.۲ Meerkat ۴
۶.۲ MedMobile ۵

۳ دیتاست‌ها ۶
۱.۳ HeadQA ۶
۲.۳ MedMCQA ۶
۳.۳ MedQA ۷
۴.۳ MMLU (Medical) ۷
۵.۳ PubMedQA ۷
۶.۳ CareQA ۸
۷.۳ Medbullets و JAMA Clinical Challenge ۸
۸.۳ دیتاست‌های مدل Aloe ۸
۹.۳ دیتاست‌های MedRAG ۹
۱۰.۳ UltraMedical ۱۰
۱۱.۳ K-QA ۱۰

۴ ارزیابی و انتخاب مدل ۱۱
۱.۴ مدل‌های فارسی زبان ۱۱
۱.۱.۴ aya-23-8B ۱۱
۲.۱.۴ aya-expanse-8b ۱۱
۳.۱.۴ gemma-2-2b-it ۱۲
۴.۱.۴ c4ai-command-r7b ۱۲
۵.۱.۴ gemma-2-9b-it ۱۲
۶.۱.۴ gemma-2-9b-it-bnb-4bit ۱۲
۷.۱.۴ gemma-2-27b-it-bnb-4bit ۱۲
۲.۴ روش‌های ارزیابی ۱۲

۱.۲.۴ سوالات چندگزینه‌ای ۱۲
۲.۲.۴ BERTScore ۱۳
۳.۲.۴ Hallucination ۱۴

۵ ارتقای دانش داخلی ۱۸
۱.۵ کتابخوانه‌ها ۱۸
۱.۱.۵ HuggingFace Transformers ۱۸
۲.۱.۵ Llama Factory ۱۸
۳.۱.۵ Axolotl ۱۸
۴.۱.۵ Torch XLA ۱۹
۵.۱.۵ NVIDIA NeMo ۱۹
۶.۱.۵ Xtunner ۱۹
۷.۱.۵ Unslot ۲۰
۲.۵ Supervised Fine-Tuning ۲۰
۱.۲.۵ روش‌ها ۲۰
۲.۲.۵ گزارش Supervised Fine-Tuning مدل ۲۴
۳.۵ Alignment ۲۴
۱.۳.۵ RLHF ۲۴
۲.۳.۵ DPO ۲۵
۳.۳.۵ KTO ۲۶
۴.۳.۵ ORPO ۲۷
۵.۳.۵ گزارش Alignment مدل ۲۹

۶ ارتقای دانش خارجی ۳۰
۱.۶ فریم‌ورک‌ها ۳۰
۱.۱.۶ LangChain ۳۰
۲.۱.۶ Llama-Index ۳۱
۲.۶ رویکردهای RAG ۳۳
۱.۲.۶ Vector Database RAG ۳۳
۲.۲.۶ Graph RAG ۳۵
۳.۲.۶ Light RAG ۳۶
۴.۲.۶ اعمال RAG روی مدل ۳۸
۳.۶ رویکردهای Prompt engineering ۳۸
۱.۳.۶ CoT ۳۹
۲.۳.۶ sc-CoT ۳۹
۳.۳.۶ CoK ۴۱
۴.۳.۶ ToT ۴۲
۵.۳.۶ اعمال Prompt engineering روی مدل ۴۲

۷ رابط کاربری چت ۴۴

۸ کارهای بیشتر ۴۶
۱.۸ مبدل صوت به متن (ASR) ۴۶
۲.۸ مبدل متن به صوت (TTS) ۴۶
۳.۸ مدل‌های (VLM) ۴۶
۴.۸ Instruction tuning ۴۶
۵.۸ آموزش کامل مدل (Pre-training) ۴۶

۹ نتیجه گیری ۴۷

فهرست تصاویر

۱.۴ شبیه سازی نحوه کارکرد BERTSCORE ۱۳

۱.۵ عملکرد LoRA ۲۱
۲.۵ مقایسه Full Fine-tuning با روش‌های LoRA و QLoRA ۲۲
۳.۵ (a) راهکار فقط ابری. (b) راهکار فقط لبه‌ای. (c) طرح DLoRA. پارامترهای ثابت و قابل یادگیری به ترتیب با رنگ نارنجی و قرمز نشان داده شده‌اند. ۲۳
۴.۵ مقایسه روش DPO با RLHF ۲۵
۵.۵ ORPO، DPO و RLHF ۲۹

۱.۶ شبیه سازی RAG پایه ۳۴
۲.۶ روند اجرا و استفاده از Vector Database RAG ۳۵
۳.۶ روند اجرا و استفاده از Graph RAG ۳۶
۴.۶ تقسیم گراف به بخش‌هایی مختلف ۳۷
۵.۶ تقسیم گراف به بخش‌هایی مختلف ۳۷
۶.۶ مقایسه ورودی CoT با ورودی عادی ۴۰
۷.۶ مقایسه روش CoT با روش sc-CoT ۴۰
۸.۶ چارچوب زنجیره‌ای از دانش (CoK)، شامل (I) آماده‌سازی استدلال، (II) تطبیق دانش پویا، و (III) یکپارچه‌سازی پاسخ است. ۴۱
۹.۶ مقایسه روش CoT روش، sc-CoT و روش CoK ۴۲
۱۰.۶ مقایسه روش CoT روش، sc-CoT و روش ToT ۴۳

۱.۷ رابط کاربری ایجاد شده برای تعامل با مدل (تصویر خالی) ۴۴
۲.۷ رابط کاربری ایجاد شده برای تعامل با مدل (تصویر همراه با چت) ۴۵

فهرست جداول

۱.۴ ارزیابی با سوالات چندگزینه‌ای ۱۵
۲.۴ نتایج ارزیابی مدل‌های فارسی زبان در سوالات چندگزینه‌ای ۱۶
۳.۴ محاسبه نرخ توهم (Hallucination) دو متن. ۱۷

۱.۵ مقایسه روش DPO با RLHF ۲۶
۲.۵ مقایسه روش‌های KTO، DPO و RLHF ۲۸
۳.۵ جدول مقایسه ORPO، DPO و RLHF ۲۹

۱.۶ تفاوت‌های Vector Database RAG، Graph RAG و Light RAG ۳۸

فصل ۱

مقدمه

مدل‌های زبانی بزرگ[1] به‌عنوان یکی از پیشرفت‌های برجسته در حوزه هوش مصنوعی و پردازش زبان طبیعی (NLP) شناخته می‌شوند. این مدل‌ها، که بر پایه معماری قدرتمند ترنسفورمر طراحی شده‌اند، توانایی درک و تولید متن را با دقت بالا دارند. معماری ترنسفورمر، با استفاده از مکانیزم توجه[2]، وابستگی‌های میان کلمات در متن را یاد می‌گیرد و امکان تحلیل دقیق آن را فراهم می‌کند. این مدل‌ها ابتدا متن ورودی را به توکن‌هایی تبدیل می‌کنند و سپس هر توکن را به یک بردار عددی در فضای برداری تبدیل می‌کنند. مکانیزم Self-Attention وابستگی میان توکن‌ها را محاسبه کرده و اطلاعات را به شکلی سازمان‌یافته پردازش می‌کند. همچنین، استفاده از Positional Encoding ترتیب کلمات را حفظ کرده و مدل را قادر می‌سازد تا توالی‌های طولانی را درک کند. [۱]

این مدل‌ها در دو مرحله اصلی آموزش داده می‌شوند. مرحله اول پیش‌آموزش[3] است که در آن مدل با استفاده از داده‌های متنی عظیم، ساختار و معنای زبان را یاد می‌گیرد. در مرحله دوم، مدل از طریق تنظیم دقیق[4] روی داده‌های خاص یک کاربرد مانند ترجمه، چت یا خلاصه‌سازی متن، تنظیم می‌شود. برخی از مدل‌ها نیزعلاوه بر فاین‌تیونینگ، از روش‌هایی مانند یادگیری تقویتی با بازخورد انسانی[5] بهره می‌گیرند تا کیفیت پاسخ‌ها را بهبود بخشند. به کمک این رویکردها، مدل‌های زبانی توانسته‌اند در تولید متون طبیعی، درک زبان انسانی و انجام وظایف پیچیده‌ای نظیر پاسخ‌گویی به پرسش‌ها و تحلیل داده‌های متنی عملکرد بی‌نظیری دارند .

با پیشرفت مدل‌های زبانی، رویکردهای جدیدی مانند RAG[6] نیز ظهور کرده‌اند. RAG با ترکیب مدل‌های زبانی و پایگاه‌های داده خارجی، عملکرد مدل‌ها را بهبود می‌بخشد.[۲] به‌جای اتکا به پارامترهای داخلی، RAG اطلاعات دقیق و به‌روز را از منابع خارجی که در ساختارهای Vector Database یا Graph Database ذخیره شده‌اند بازیابی و در اختیار مدل فرار می‌دهد. Vector Database با ذخیره داده‌ها به شکل بردارهای تعبیه‌شده، امکان جستجوی سریع بر اساس مشابهت معنایی را فراهم می‌کند که باعث بهبود پاسخگویی در سوالات کلی می‌شود، در حالی که Graph Database برای مدل‌سازی روابط پیچیده و شبکه‌های دانش مناسب است. این ترکیب به مدل اجازه می‌دهد تا در پاسخ به سوالات پیچیده و جزئی که نیاز به فراهم کردن اطلاعات دقیق‌تر و جزئی‌تر دارند، توانایی بیشتری از خود نشان دهد. [۳] [۴]

---

[1] Large Language Models
[2] Attention Mechanism
[3] Pretraining
[4] Fine-Tuning
[5] Reinforcement Learning from Human Feedback (RLHF)
[6] Retrieval-Augmented Generation

یکی دیگر از مباحث کلیدی در بهبود عملکرد مدل‌های زبانی، Prompt Engineering یا هدایت مدل به تولید پاسخ‌های دقیق‌تر با استفاده از ورودی که به مدل داده می‌شود است. در این مبحث توانایی مدل را بدون تنظیم مدل روی حوزه خاص ارتقا می‌دهیم. [۵] رویکردهای متنوعی در این زمینه توسعه یافته‌اند. به‌عنوان مثال، در روش زنجیره تفکر[۷] که مدل را به ارائه پاسخ‌هایی گام‌به‌گام هدایت می‌کند که برای مسائل پیچیده مانند ریاضیات یا استدلال منطقی وادار می‌کند که در آن دقیقا مانند ما انسان‌ها که مسائل را بخش بخش حل می‌کنیم سوال را به بخش‌های مختلف و ساده‌تری تقسیم می‌کند که باعث می‌شود مدل بتواند راحت‌تر و دقیق تر به سوالات پاسخ بدهد. استفاده از این تکنیک‌های مانند این، به‌ویژه در وظایفی مانند پرسش و پاسخ پیچیده یا برنامه‌ریزی، به‌طور قابل‌توجهی کیفیت و دقت خروجی‌ها را افزایش می‌دهد. [۶] [۷]

در نهایت مدل‌ها را می‌توان با استفاده این روش‌ها به متخصصی در حوزه خاص تبدیل کرد که سوالات مختلف را پاسخ بدهد. و در این پروژه هدف من این است که با بررسی و استفاده از این روش‌ها و موارد مشابه مدل زبانی تخصصی در حوزه پزشکی ایجاد کنم که به عنوان دستیار پزشکی به سوالات پزشکی به خوبی پاسخ دهد. روند انجام این پروژه بدین صورت است که ابتدا موارد مشابه بررسی می‌شوند و سپس به بررسی داده‌های موجود در این حوزه پرداخته می‌شود.

پس از آن روش‌های ارزیابی مدل‌ها را بررسی و اقدام به ارزیابی مدل‌های فارسی می‌پردازم. سپس مدل قوی‌تر را در دو فاز دانش داخلی و خارجی ارتقا می‌دهم که خود ارتقای داخلی شامل SFT[۸] و Alignment است که ابتدا روش‌های موجود در هرکدام بررسی و مقایسه و بهترین روش انتخاب و روی مدل پیاده سازی می‌شود تا مدل پایه به دست آید. پس از آن به بررسی روش‌های موجود برای افزایش دانش داخلی یعنی انواع RAG سیستم‌ها پرداخته می‌شود. پس از آن روش‌های prompt engineering بررسی می‌شوند و پس از آن رابط کاربری ساده‌ای برای تعامل با مدل ایجاد می‌شود. در نهایت به امکانات دیگری که میتوان به این دستیار اضافه کرد پرداخته می‌شود که که به دلایل محدودیت‌های سخت افزاری و یا اطلاعاتی امکان انجام آن را نداشتم.

[7] Chain of Thought (CoT)
[8] Supervised Fine-Tuning

فصل ۲

پژوهش‌های مشابه

در این بخش پژوهش‌های مشابه که به صورت تخصصی در این حوزه انجام و منجر به ایجاد مدل زبانی تخصصی برای دستیار پزشکی شده‌اند را بررسی می‌کنیم.

Med-PaLM ۱.۲

در این پژوهش به صورت هماهنگ بر توسعه و بهبود کاربرد مدل‌های زبانی بزرگ[1] در حوزه پزشکی تمرکز دارند و با هم پیشرفت‌های چشمگیری در این زمینه نشان می‌دهند. در هر دو مقاله، از مدل‌های پیشرفته زبانی مانند PaLM و Flan-PaLMاستفاده شده و نسخه‌های تخصصی این مدل‌ها، یعنی Med-PaLM و Med-PaLM 2، برای هم‌راستایی با نیازهای خاص پزشکی توسعه یافته‌اند. تلاش‌ها بر بهبود دقت، استدلال، و علمی بودن پاسخ‌ها متمرکز بوده است، که با استفاده از تکنیک‌هایی مانند زنجیره تفکر[2] و زنجیره تفکر خودسازگار[3]، و تنظیم دستورالعمل ورودی به مدل انجام شد. برای ارزیابی عملکرد این مدل‌ها، معیار جامع MultiMedQA شامل داده‌های متنوع چندگزینه‌ای و پاسخ‌های بلند توسعه یافته است. نتایج نشان داده که مدل‌های بهبودیافته می‌توانند در معیارهای مختلف مانند پاسخ‌دهی دقیق، کاهش محتوای نادرست، و پاسخ‌های معتبر عملکردی نزدیک به پزشکان داشته باشند. با این حال، هر دو مقاله بر چالش‌های باقی‌مانده مانند نیاز به داده‌های متنوع‌تر، تعصبات بالقوه، و ارزیابی در سناریوهای واقعی بالینی تأکید می‌کنند. این پژوهش‌ها به‌طور کلی گامی اساسی در جهت استفاده امن و مؤثر از مدل‌های زبانی در کاربردهای حساس پزشکی به شمار می‌آیند. [۸] [۹]

Meditron ۲.۲

این پژوهش به معرفی مدل‌های MEDITRON که در دو مقیاس ۷ و ۷۰ میلیارد پارامتر ارائه شده‌اند می‌پردازد که با هدف بهبود دسترسی به دانش پزشکی و تقویت مدل‌های متن‌باز تخصصی در حوزه پزشکی ایجاد شده‌اند. این مدل‌ها با استفاده از معماری Llama-2 و آموزش کامل[4] بر روی داده‌های جامع پزشکی شامل مقالات PubMed، دستورالعمل‌های بالینی، و داده‌های عمومی توسعه یافته‌اند. ارزیابی‌ها نشان داد که MEDITRON در معیارهای اصلی پزشکی مانند MedQA و PubMedQA عملکردی بهتر از

[1] LLMs
[2] CoT
[3] sc-CoT
[4] Pre-train

مدل‌های متن‌باز موجود دارد و در برخی موارد با مدل‌های تجاری بسیار بزرگ‌تر مانند GPT-4 رقابت می‌کند. همچنین، استفاده از روش‌های استنتاج پیشرفته مانند زنجیره استدلال (CoT) و زنجیره استدلال با خودسازگاری (cs-CoT) موجب بهبود قابل‌توجه عملکرد مدل شده است. انتشار متن‌باز ابزارها، کدها، و منابع این پژوهش، امکان ارزیابی واقعی مدل و توسعه بیشتر مدل‌های زبانی تخصصی در حوزه‌های مختلف، به‌ویژه پزشکی، را فراهم می‌کند. [۱۰]

BioMistral ۳.۲

این پژوهش به معرفی BioMistral 7B می‌پردازد، یک مدل زبان بزرگ متن‌باز تخصصی برای حوزه پزشکی که با استفاده از مدل پایه Mistral 7B Instruct و بازآموزی بر داده‌های علمی PubMed Central توسعه یافته است. هدف از این پژوهش، ایجاد مدلی با عملکرد برتر در وظایف پزشکی در کنار حفظ قابلیت‌های عمومی مدل‌های زبان بزرگ است. ارزیابی مدل در یک معیار متشکل از ۱۰ وظیفه پرسش و پاسخ پزشکی در زبان انگلیسی بوده که پس از آن به ۷ زبان دیگر ترجمه و ارزیابی شد و نتایج به دست آمده نشان داد که BioMistral 7B در بیشتر وظایف بر مدل‌های متن‌باز موجود برتری دارد و در برخی موارد به مدل‌های اختصاصی نزدیک می‌شود. همچنین، با استفاده از تکنیک‌های کوانتیزه‌سازی[۵] و ادغام مدل[۶]، بهره‌وری و عملکرد آن بهبود یافته است. علاوه بر این، مدل در زبان‌های مختلف و ویژگی‌هایی مانند کالیبراسیون[۷] و حقیقت‌گرایی[۸] نیز ارزیابی شد و نتایج قابل قبولی ارائه کرد. در نهایت، این پژوهش به انتشار داده‌ها و مدل‌ها در پلتفرم‌های متن‌باز پرداخته و پیشنهادهایی برای بهبود قابلیت‌های چندزبانه و مکالمه‌ای مدل ارائه داده است. [۱۱]

Aloe ۴.۲

مدل‌های Aloe به‌عنوان مجموعه‌ای از مدل‌های متن‌باز برای کاربردهای پزشکی توسعه یافته‌اند. این فرایند با انتخاب مدل‌های پایه مناسب مانند Mistral-7B و Llama 3-8B آغاز شد و از طریق تنظیم‌دقیق[۹] با داده‌های عمومی و پزشکی بهینه‌سازی شده است. برای افزایش دقت، از داده‌های مصنوعی به سبک زنجیره تفکر[۱۰] و تکنیک ادغام مدل‌ها استفاده شد که بدون افزایش اندازه مدل، عملکرد آن را بهبود بخشید. در مراحل بعدی، تنظیم ترجیحات انسانی با روش DPO [۱۱] برای شناسایی و کاهش خطرات و پاسخ‌های مضر انجام گرفت. همچنین، تکنیک‌های پیشرفته طراحی ورودی مانند Medprompt باعث افزایش چشمگیر دقت مدل در پاسخگویی به سوالات پزشکی شد. نسخه نهایی Llama3-Aloe-8B-Alpha با تمرکز بر شفافیت، اخلاق و قابلیت بازتولید منتشر شد. [۱۲]

Meerkat ۵.۲

مدل Meerkat با هدف ایجاد یک سیستم هوش مصنوعی پزشکی متن‌باز با قابلیت استدلال زنجیری و پیشرفته توسعه یافت. این پروژه با انتخاب معماری‌های پیشرفته مانند Mistral-7B و LLaMA-3

[5] Quantization
[6] Model Merging
[7] Calibration
[8] Truthfulness
[9] Supervised Fine-Tuning
[10] Chain of Thought
[11] Direct Preference Optimization

آغاز شد، که به دلیل قابلیت پردازش سریع و دقت بالا به عنوان پایه انتخاب شدند. سپس، با طراحی و تولید مجموعه داده‌های آموزشی متنوع، شامل داده‌های زنجیره تفکر استخراج‌شده از ۱۸ کتاب درسی پزشکی، مجموعه داده MedBooks-CoT-18 اماده شد و بیش از ۷۸،۰۰۰ سؤال تولیدشده توسط GPT-4، مدل برای حل مسائل پیچیده پزشکی نیز آماده شد. برای افزایش توانایی مدل در پاسخ به سؤالات واقعی بالینی، از مجموعه داده‌های موجود مانند MedMCQA و LiveQA استفاده شد و داده‌های دیگری همچون ChatDoctor-cleaned و MedQA-dialogue برای تقویت قابلیت مکالمات چندمرحله‌ای طراحی شدند. این داده‌ها با استفاده از تکنیک‌های پیشرفته مانند FlashAttention پردازش و آموزش مدل‌ها با استفاده از GPUها و TPUها انجام شد. مدل‌ها با معیارهای مختلف از جمله MedQA و چالش‌های NEJM ارزیابی شدند، که نتایج نشان داد Meerkat-7B اولین مدل 7B بود که مرز نمره قبولی USMLE را عبور کرد و Meerkat-70B توانست با GPT-4 رقابت کند و حتی در برخی معیارها عملکرد بهتری داشته باشد. این رویکرد، ترکیبی از معماری‌های کارآمد، داده‌های آموزشی غنی، و روش‌های پیشرفته ارزیابی را به کار گرفت تا مدلی مؤثر و دقیق برای حل چالش‌های پزشکی ارائه دهد. [۱۳]

MedMobile ۶.۲

مدل MedMobile با هدف ایجاد یک دستیار پزشکی کوچک، کم‌هزینه، و تخصصی توسعه یافت که بتواند روی دستگاه‌های همراه اجرا شود و نیازی به زیرساخت‌های محاسباتی پیچیده نداشته باشد. توسعه این مدل با استفاده از phi-3-mini به عنوان مدل پایه انجام شد، مدلی متن‌باز با ۸.۳ میلیارد پارامتر که برای کاربرد در دستگاه‌های همراه مناسب بود. تیم تحقیقاتی با استفاده از مجموعه داده‌های پزشکی UltraMedical شامل بیش از ۴۰۰ هزار پرسش چندگزینه‌ای پزشکی، مدل را از طریق فرآیند تنظیم دقیق نظارت‌شده[۱۲] آموزش دادند. این داده‌ها ترکیبی از نمونه‌های دستی (توسط متخصصان) و مصنوعی (ایجادشده توسط GPT-4 و منابع مرجع پزشکی) بودند. با استفاده از تکنیک‌های پیشرفته مانند زنجیره استدلال (CoT)، دانش و فرآیند استدلال منطقی GPT-۴ به مدل کوچک‌تر منتقل شد. برای بهبود دقت، روش یادگیری جمعیEnsembling به کار گرفته شد که چندین پاسخ را ترکیب کرده و دقیق‌ترین آن را انتخاب می‌کرد. علاوه بر این، دستورات ورودی مدل با ابزار TextGrad بهینه‌سازی شدند، اما محدودیت‌های مربوط به پنجره متنی در مدل‌های کوچک باعث شد که استفاده از دستورات اضافی عملکرد مدل را کاهش دهد. همچنین، روش‌های دیگری مانند بازیابی مبتنی بر اطلاعات[۱۳] و k-shot prompting نیز آزمایش شدند، اما به دلیل پیچیدگی و افزایش طول ورودی، تاثیر قابل‌توجهی بر عملکرد نداشتند. در نهایت، MedMobile با عملکرد ۷۴.۷۵٪ در آزمون MedQA (USMLE) موفق شد به عنوان اولین مدل زیر ۵ میلیارد پارامتر نمره قبولی در این آزمون را کسب کند، که این دستاورد نشان‌دهنده توانایی بالای مدل در اجرای وظایف تخصصی پزشکی در عین حفظ کارایی و هزینه پایین است. [۱۴]

[12] SFT
[13] RAG

فصل ۳

دیتاست‌ها

در این بخش دیتاست‌های استفاده شده در پژوهش‌های مشابه را بررسی می‌کنیم.

HeadQA ۱.۳

دیتاست HEAD-QA به‌منظور ارزیابی مدل‌های پاسخ‌دهی به سوالات چندگزینه‌ای در حوزه‌های پیچیده‌ای مانند پزشکی، پرستاری، روانشناسی، شیمی، زیست‌شناسی و داروسازی ایجاد شده است. سوالات این دیتاست از امتحانات رسمی تخصصی سیستم بهداشت اسپانیا (۲۰۱۳ به بعد) استخراج شده و شامل سوالات متنی و گاهی همراه با تصاویر می‌باشد. سوالات بر اساس حوزه دسته‌بندی شده و اطلاعات آن‌ها در قالب ساختار JSON شامل متن سوال، گزینه‌ها، پاسخ صحیح و شناسه سوال ذخیره شده است. این دیتاست به مجموعه‌های آموزشی، توسعه و آزمایشی تقسیم شده تا امکان مقایسه با عملکرد انسانی فراهم شود. همچنین، نسخه‌ای از دیتاست به انگلیسی ترجمه شده که کیفیت ترجمه آن توسط کارشناسان بررسی شده است. در آزمایش‌ها، مدل‌های مختلف از جمله روش‌های اطلاعات‌بازیابی و معماری‌های پیشرفته مانند BiDAF و DrQA به‌کار گرفته شدند که نشان داد این دیتاست برای مدل‌های موجود چالش‌برانگیز است. این مجموعه داده‌ها به‌عنوان مرجعی برای تحقیق در زمینه پاسخ‌دهی به سوالات پیچیده و چندزبانه طراحی شده است. [۱۵]

MedMCQA ۲.۳

یک مجموعه داده بزرگ‌مقیاس و چندموضوعی پرسش و پاسخ چندگزینه‌ای در حوزه پزشکی که شامل بیش از ۱۹۴ هزار سؤال از آزمون‌های ورودی پزشکی AIIMS و NEET PG است. این مجموعه داده، ۲۴۰۰ موضوع مرتبط با سلامت و ۲۱ رشته پزشکی را پوشش می‌دهد و برای ارزیابی توانایی‌های استدلالی و درک زبان طبیعی مدل‌ها طراحی شده است. سؤالات چالش‌برانگیز این مجموعه که توسط متخصصان انسانی طراحی شده‌اند، نیازمند تحلیل عمیق و مهارت‌های استدلالی مشابه با انسان هستند. در فرآیند آماده‌سازی، داده‌ها از منابع معتبر جمع‌آوری شده و با حذف سؤالات بی‌کیفیت و رفع اشکالات نگارشی و دستوری، کیفیت آن‌ها تضمین شده است. ارزیابی مدل‌های مختلف مبتنی بر معماری ترانسفورمر مانند BERT، BioBERT، SciBERT و PubMedBERT نشان می‌دهد که هنوز فاصله قابل‌توجهی با عملکرد انسانی دارد. این مجموعه داده با ارائه چالش‌هایی منحصربه‌فرد در تنوع موضوعات، کیفیت بالا و نیاز به استدلال زنجیری، بستری مناسب برای پیشرفت پژوهش‌های آینده در حوزه پرسش و پاسخ پزشکی

ایجاد کرده است. [۱۶]

MedQA ۳.۳

مجموعه داده MEDQA شامل سوالات چندگزینه‌ای آزمون‌های پزشکی از ایالات متحده (USMLE)، چین (MCMLE)، و تایوان (TWMLE) است که از منابع آنلاین و رسمی جمع‌آوری شده‌اند. این سوالات به همراه مجموعه متنی از ۱۸ کتاب پزشکی برای انگلیسی و ۳۳ کتاب برای چینی، که از طریق OCR متنی شده‌اند، آماده‌سازی شده است. فرایند پردازش شامل پاکسازی متون، حذف کلمات غیرمرتبط با ابزارهایی مانند MetaMap، و تقسیم‌بندی متون به پاراگراف‌ها بوده است. ارزیابی پوشش اطلاعات نشان داد که متون جمع‌آوری‌شده به طور عمده قادر به پاسخ‌دهی به سوالات هستند (پوشش ۸۸ تا ۱۰۰ درصدی). MEDQA در مقایسه با سایر مجموعه داده‌های مشابه، به دلیل پوشش چندزبانه، تعداد زیاد سوالات (۱۲،۷۲۳ برای انگلیسی، ۳۴،۲۵۱ برای چینی ساده)، و نیاز به استدلال چندمرحله‌ای، یک چالش منحصربه‌فرد برای مدل‌های هوش مصنوعی ایجاد می‌کند. همچنین، برخلاف دیگر مجموعه داده‌های پزشکی که بر بازیابی متن‌های کوتاه تمرکز دارند، MEDQA به دلیل نیاز به تحلیل دانش تخصصی و استنتاج پیچیده، به پیشرفت مدل‌ها کمک شایانی می‌کند. [۱۷]

MMLU (Medical) ۴.۳

برای جمع‌آوری مجموعه داده‌های آزمون چندوظیفه‌ای، سوالات از منابع معتبر آموزشی و حرفه‌ای، نظیر آزمون‌های عمومی GRE و USMLE، کتاب‌های دانشگاهی، و منابع اینترنتی آزاد جمع‌آوری شده‌اند. این مجموعه شامل ۱۵۹۰۸ سوال چندگزینه‌ای است که به دسته‌های توسعه، ارزیابی، و آزمون تقسیم شده‌اند. سوالات در ۵۷ موضوع از علوم انسانی، علوم اجتماعی، علوم پایه و فنی و موضوعات متفرقه دسته‌بندی شده و در سطوح مختلف از دبیرستان تا حرفه‌ای طراحی شده‌اند. برخلاف سایر مجموعه‌های داده که عمدتاً بر مهارت‌های زبانی یا موضوعات محدود تمرکز دارند، این مجموعه با پوشش گسترده موضوعات و دشواری‌های مختلف، توانایی مدل‌ها را در یادگیری دانش عمومی و حل مسئله ارزیابی می‌کند. به طور مثال نتایج ارزیابی نشان داده است که مدل‌هایی مانند GPT-3 در برخی حوزه‌ها (مانند سیاست خارجی) عملکرد نسبتاً خوبی دارند اما در موضوعات محاسباتی و اجتماعی مانند ریاضیات یا اخلاق همچنان چالش‌برانگیز هستند. در مقایسه با سایر مجموعه‌ها، این داده‌ها ابزار بهتری برای سنجش توانایی‌های واقعی مدل‌ها ارائه می‌دهند و به شناسایی نقاط ضعف و قوت آن‌ها کمک می‌کنند. در این پروژه تنها مباحث پزشکی این مجموعه داده مورد بررسی است. [۱۸]

PubMedQA ۵.۳

PubMedQA یک دیتاست نوآورانه برای پاسخ‌گویی به سوالات پژوهشی زیست‌پزشکی است که شامل سه بخش اصلی است:

- داده‌های برچسب‌گذاری شده (PQA-L) با ۱۰۰۰ نمونه که توسط متخصصان برای ارزیابی و اعتبارسنجی تولید شده‌اند.
- داده‌های بدون برچسب (PQA-U) شامل ۲۰۶۱ هزار نمونه که برای یادگیری نیمه‌نظارتی مناسب است.

- داده‌های مصنوعی (PQA-A) با ۳۰۲۱۱ هزار نمونه که از تبدیل عناوین بیانیه‌ای مقالات به سوالات به همراه برچسب‌های خودکار تولید شده است.

این دیتاست با تمرکز بر سوالات "بله"، "خیر"، و "شاید" طراحی شده و نیازمند استدلال پیچیده و تفسیر داده‌های کمی است. در مقایسه با سایر دیتاست‌های مشابه مانند BioASQ، PubMedQA بزرگ‌ترین مجموعه در زمینه خود است و با استفاده از مقالات ساختارمند PubMed و بهره‌گیری از نتایج پژوهش‌ها به‌عنوان پاسخ‌های طولانی، دقت و انسجام بالایی دارد. برخلاف بسیاری از دیتاست‌های عمومی مانند SQuAD یا HotpotQA، PubMedQA برای کاربردهای تخصصی پزشکی طراحی شده و با بهره‌گیری از داده‌های مصنوعی و روش‌های زنجیره تفکر، موجب پیشرفت قابل‌توجهی در پاسخ‌دهی به سوالات پیچیده پزشکی ارائه می‌دهد. [۱۹]

۶.۳ CareQA

CareQA یک مجموعه داده‌ی منحصربه‌فرد است که شامل ۵،۶۲۰ پرسش چندگزینه‌ای در زمینه پزشکی است. این پرسش‌ها در ابتدا به زبان اسپانیایی تهیه شده و سپس به انگلیسی ترجمه شده‌اند. هدف اصلی این مجموعه داده، تسهیل توسعه و ارزیابی مدل‌های پردازش زبان طبیعی (NLP) در حوزه پزشکی است. CareQA توسط گروه (HPAI-BSC) طراحی و منتشر شده است. [۱۲]

۷.۳ Medbullets و JAMA Clinical Challenge

با هدف ارزیابی مدل‌های زبانی بزرگ در پاسخ‌دهی و توضیح به سوالات پزشکی پیچیده، دو دیتاست جدید به نام‌های JAMA Clinical Challenge و Medbullets را معرفی شده است. دیتاست JAMA Clinical Challenge شامل ۱۵۲۴ نمونه واقعی از موارد بالینی چالش‌برانگیز است که از آرشیو Clinical Challenge مجله JAMA جمع‌آوری شده و شامل سوالات چندگزینه‌ای همراه با توضیحات نوشته‌شده توسط متخصصین است. Medbullets نیز شامل ۳۰۸ سوال از نوع USMLE Step 2/3 است که از توییت‌های Medbullets به‌روز جمع‌آوری شده و با توضیحات کامل هر گزینه همراه است. این دیتاست‌ها به دلیل پوشش موضوعات بالینی پیچیده و توضیحات تفصیلی، چالش بیشتری نسبت به دیتاست‌های موجود مانند MedQA دارند. همچنین، به دلیل جدید بودن سوالات احتمال کمتری برای وجود داشتن در داده‌های پیش‌آموزش مدل‌های زبانی وجود دارد. ارزیابی هفت مدل زبانی از جمله GPT-4 و Llama 2 روی این دیتاست‌ها نشان داد که این مدل‌ها با چالش‌های قابل توجهی در استدلال و ارائه توضیحات برای سوالات بالینی مواجه هستند، که نشان‌دهنده نیاز به پیشرفت در توانایی‌های این مدل‌ها برای تصمیم‌گیری‌های پیچیده پزشکی است. [۲۰]

۸.۳ دیتاست‌های مدل Aloe

- MedS-Ins
- Aloe-Beta-DPO
- MedRAG wikipedia
- medqa-cot
- medmcqa-cot

- MMLU-medical-cot-llama31
- medqa-cot-llama31
- medmcqa-cot-llama31

روند آماده‌سازی داده برای آموزش مدل‌های Aloe شامل مراحل دقیق و چندلایه‌ای است که کیفیت، تنوع و حجم داده‌ها را تضمین می‌کند. ابتدا داده‌های خام از منابع عمومی و پزشکی جمع‌آوری شده و از طریق فرآیند پاکسازی و حذف داده‌های نامربوط و تکراری پالایش می‌شوند؛ این شامل حذف کاراکترهای اضافی، استانداردسازی قالب‌بندی و استفاده از تکنیک‌های تطبیقی مانند Minhash برای شناسایی و حذف داده‌های تکراری است. سپس فرآیند Decontamination انجام می‌شود تا از استفاده ناخواسته از داده‌های آزمایشی جلوگیری شود. در مرحله بعد، داده‌های پزشکی موجود با استفاده از مدل‌های پیشرفته‌تر تقویت می‌شوند؛ این کار شامل تولید پاسخ‌ها با استفاده از زنجیره تفکر[1] و اضافه کردن سوالات و پاسخ‌های مصنوعی با استفاده از تکنیک‌های تولید داده است. برای تنوع بیشتر، الگوهای متنوعی به صورت دستی برای سوالات و پاسخ‌ها طراحی می‌شوند. در نهایت، مجموعه داده‌های انتخابی برای هم‌ترازی ترجیحات مدل مورد استفاده قرار می‌گیرند که شامل شناسایی نقاط ضعف مدل از طریق داده‌های Red Teaming و اصلاح آن‌ها با ترکیب داده‌های با کیفیت بالا است. این فرآیند جامع تضمین می‌کند که مدل بتواند در سناریوهای پزشکی به صورت دقیق، ایمن و اخلاقی عمل کند. [۱۲]

۹.۳ دیتاست‌های MedRAG

- MedRAG textbooks
- MedRAG pubmed
- MedRAG wikipedia
- MedRAG StatPearls
- MedRAG MedCorp

این داده ها مجموعه‌ای متنوع از دیتاست‌ها برای ارزیابی سیستم‌های بازیابی و تولید اطلاعات پزشکی استفاده شده است. این دیتاست‌ها شامل PubMed، که مجموعه‌ای گسترده از مقالات و خلاصه‌های بیومدیکال است و برای بازیابی اطلاعات علمی به کار می‌رود؛ StatPearls، که به ارائه اطلاعات بالینی برای پشتیبانی از تصمیم‌گیری پزشکان می‌پردازد؛ و StatPearls، که شامل محتوای تخصصی پزشکی از کتاب‌های مرجع است و برای سوالات مرتبط با آزمون‌های پزشکی مفید می‌باشد. همچنین از Wikipedia به عنوان منبع دانش عمومی استفاده شده است که امکان دسترسی به اطلاعات مقدماتی در موضوعات متنوع را فراهم می‌کند. در نهایت، MedCorp، که ترکیبی از تمام منابع فوق است، به‌عنوان یک مجموعه جامع برای دسترسی به داده‌های چندمنظوره طراحی شده است. هر یک از این منابع بسته به نوع سوالات و نیازمندی‌های ارزیابی، نقش مهمی در بهبود عملکرد RAG سیستم ایفا می‌کنند. [۲۱]

[1] Chain of Thought

۱۰.۳ UltraMedical

دیتاست UltraMedical با هدف ارتقاء مدل‌های زبان بزرگ در حوزه پزشکی از طریق جمع‌آوری و مقایسه داده‌های متنوع و باکیفیت ساخته شده است. این دیتاست شامل حدود ۴۱۰ هزار سوال و پاسخ است که از منابع متنوعی مانند سوالات امتحانی پزشکی، مقالات علمی و سوالات باز جمع‌آوری شده‌اند و به‌صورت دستی و مصنوعی تولید شده‌اند. اصول تنوع با ترکیب داده‌های مختلف و استفاده از مدل‌های پیشرفته برای تکامل خودکار داده‌ها رعایت شده است، درحالی‌که اصول پیچیدگی با تولید سوالات چالش‌برانگیز از طریق پیش‌پردازش و پس‌پردازش تقویت شده است. پاسخ‌ها توسط مدل‌های قدرتمندی مانند GPT-4 تولید و با روش‌هایی نظیر زنجیره تفکر بهینه‌سازی شده‌اند. همچنین، ترجیحات پاسخ‌ها از طریق رتبه‌بندی مدل‌ها جمع‌آوری و برای آموزش مدل‌های پاداش استفاده شده‌اند که این مدل‌ها قادر به ارزیابی و رتبه‌بندی پاسخ‌ها هستند. به‌منظور مقایسه با دیگر دیتاست‌ها، عملکرد مدل‌ها در معیارهایی مانند دقت سوالات چندگزینه‌ای و پاسخ به سوالات بالینی ارزیابی شده است و یافته‌ها نشان داده‌اند که ترکیب داده‌های پزشکی و عمومی می‌تواند توانایی مدل‌ها را در هر دو حوزه بهبود بخشد. این فرآیند شامل خلاصه‌نویسی دقیق، یادگیری ترجیحی و بهینه‌سازی مستمر مدل‌ها بوده است که در نهایت مدل‌هایی با قابلیت‌های رقابتی و پیشرفته (مانند مدل ۶.۲) ایجاد کرده است. [۲۲]

۱۱.۳ K-QA

برای جمع‌آوری دیتاست K-QA، ابتدا پرسش‌های واقعی کاربران از پلتفرم K Health که شامل تعاملات بین کاربران و پزشکان بود، جمع‌آوری شد. پس از یک مرحله پیش‌پردازش اولیه با استفاده از مدل‌های زبانی مانند BERT، پرسش‌هایی که به اطلاعات پیش‌زمینه‌ای نیاز نداشتند، انتخاب شدند. تیمی از پزشکان متخصص پاسخ‌های دقیق و علمی برای این پرسش‌ها ارائه دادند. سپس این پاسخ‌ها به جملات مستقل و کوچک‌تر تقسیم شدند تا ارزیابی دقیق‌تری ممکن شود. جملات به دو دسته «باید داشته باشد»[۲] و «خوب است داشته باشد»[۳] بر اساس اهمیت پزشکی طبقه‌بندی شدند. برای ارزیابی مدل‌ها، از متریک‌های Completeness و نرخ توهم[۴] یا Factuality استفاده شد. جامعیت درصد پوشش جملات ضروری را می‌سنجد و نرخ توهم تعداد تناقضات را محاسبه می‌کند. این ارزیابی با استفاده از استنتاج زبان طبیعی[۵] انجام شد که در آن پاسخ مدل به عنوان فرض و جملات پزشک به عنوان فرضیه تحلیل می‌شدند. این فرآیند در کنار آزمایش مدل‌های پیشرفته مانند GPT-4 و روش‌های تقویت‌شده با بازیابی محتوا[۶] نشان داد که افزایش اندازه مدل و استفاده از محتواهای مرتبط می‌تواند جامعیت را بهبود داده و نرخ توهم را کاهش دهد. [۲۳]

[2] Must Have
[3] Nice to Have
[4] Hallucination Rate
[5] NLI
[6] RAG

فصل ۴

ارزیابی و انتخاب مدل

در این بخش به بررسی روش‌های ارزیابی که در پروژه‌های مشابه استفاده شده است می‌پردازیم و پس از آن مدل‌های فارسی زبان را معرفی و تست‌های مطرح شده را از مدل‌ها گرفته و بهترین مدل را برای گام‌های بعد انتخاب می‌کنیم.

۱.۴ مدل‌های فارسی زبان

۱.۱.۴ aya-23-8B

مدل Aya 23 یک خانواده از مدل‌های زبانی چندزبانه است که به‌طور خاص برای پوشش و بهبود عملکرد در ۲۳ زبان طراحی شده‌اند. این مدل‌ها با تمرکز بر تعادل بین عمق و گستردگی، از ظرفیت بیشتری برای زبان‌های منتخب استفاده کرده‌اند، که این رویکرد به‌طور قابل‌توجهی عملکرد آن‌ها را در مقایسه با مدل‌های گسترده‌تری مانند Aya 101 که ۱۰۱ زبان را پوشش می‌داد، بهبود داده است. Aya 23 بر پایه مدل‌های سری Command شرکت Cohere ساخته شده و از داده‌های PreTrain با کیفیت بالا شامل متون چندزبانه بهره برده است. این مدل در دو نسخه ۸ میلیارد و ۳۵ میلیارد پارامتری ارائه شده است که نسخه کوچکتر (Aya-23-8B) عملکرد بهینه‌ای برای سخت‌افزارهای معمولی دارد و نسخه بزرگتر (Aya-23-35B) نتایج برجسته‌ای در تمامی وظایف ارزیابی‌شده ارائه می‌دهد. Aya 23 در ارزیابی‌های مختلف، از جمله وظایف تشخیص، تولیدی، و استدلال ریاضی چندزبانه، برتر از مدل‌های پیشین مانند Gemma، Mistral و Mixtral عمل کرده است. این مدل همچنین در ترجمه و خلاصه‌سازی چندزبانه با استفاده از مجموعه داده‌هایی نظیر FLORES-200 و XLSum نتایج بهتری ارائه داده و در ارزیابی‌های انسانی و شبیه‌سازی‌شده، امتیاز بالایی کسب کرده است. [۲۴]

۲.۱.۴ aya-expanse-8b

مدل Aya Expanse خانواده‌ای از مدل‌های زبان چندزبانه است که با بهره‌گیری از تکنیک‌های پیشرفته مانند داده‌های انتخابی (Data Arbitrage)، بهینه‌سازی ترجیحات چندزبانه، و ادغام مدل‌ها توسعه یافته‌اند. این مدل‌ها با ۸ میلیارد و ۳۲ میلیارد پارامتر طراحی شده و از ۲۳ زبان شامل زبان‌های پرمنبع و کم‌منبع مانند انگلیسی، فارسی، عربی و چینی پشتیبانی می‌کنند. Aya Expanse از معماری‌های مدرن مانند SwiGLU، RoPE، و Attention بهره می‌برد و توانایی پردازش متون طولانی تا ۱۲۸ هزار توکن را دارد. این مدل‌ها در وظایفی مانند ترجمه ماشینی، استدلال ریاضی، و درک چند زبان عملکرد

برجسته‌ای دارند و حتی در مقایسه با مدل‌های بزرگ‌تر مانند Llama 3.1 70B برتری نشان داده‌اند. Aya Expanse که همراه با مجموعه داده ارزیابی جدید m-ArenaHard منتشر شده است. [۲۵]

۳.۱.۴ gemma-2-2b-it

Gemma یک خانواده از مدل‌های متن‌باز سبک و پیشرفته از گوگل است که بر اساس همان تحقیقات و فناوری‌های به‌کاررفته در ساخت مدل‌های Gemini طراحی شده‌اند. این مدل‌ها به صورت متن به متن و از نوع دیکودر هستند. وزن‌های این مدل‌ها، شامل نسخه‌های پیش‌آموزش‌یافته و نسخه‌های تنظیم‌شده بر اساس دستورات (Instruction-Tuned)، به صورت متن‌باز در دسترس قرار دارند. مدل‌های Gemma برای طیف وسیعی از وظایف تولید متن، از جمله پاسخ‌گویی به سوالات، خلاصه‌سازی و استدلال، بسیار مناسب هستند. اندازه کوچک‌تر این مدل‌ها امکان استفاده در محیط‌هایی با منابع محدود، مانند لپ‌تاپ، رایانه‌های رومیزی یا زیرساخت‌های ابری شخصی را فراهم می‌کند و دسترسی به مدل‌های هوش مصنوعی پیشرفته را همگانی کرده و نوآوری را برای همگان تقویت می‌کند.

۴.۱.۴ c4ai-command-r7b

مدل C4AI Command R7B یک نسخه پژوهشی با وزن‌های باز از یک مدل با ۷ میلیارد پارامتر است که قابلیت‌های پیشرفته‌ای دارد و برای موارد استفاده متنوعی مانند استدلال، خلاصه‌سازی، پرسش و پاسخ، و کدنویسی بهینه‌سازی شده است. این مدل برای انجام وظایف پیچیده‌ای مانند تولید با استفاده از بازیابی اطلاعات و استفاده از ابزارها آموزش دیده است. این مدل همچنین دارای قابلیت‌های قدرتمندی همچون عامل‌ها است و می‌تواند با استفاده و ترکیب چندین ابزار در چند مرحله، وظایف دشوارتری را انجام دهد. C4AI Command R7B عملکرد برتری در موارد استفاده مرتبط با کدنویسی در سطح سازمانی ارائه می‌دهد. این مدل چندزبانه بوده و بر اساس داده‌های ۲۳ زبان مختلف آموزش دیده است.

۵.۱.۴ gemma-2-9b-it

این مدل نسخه بزرگ‌تر مدل ۳.۱.۴ است.

۶.۱.۴ gemma-2-9b-it-bnb-4bit

مدل بخش ۵.۱.۴ توسط تیم Unslot (در بخش ۷.۱.۵ معرفی شده است) Quantize شده و بسیار سبک‌تر شده است.

۷.۱.۴ gemma-2-27b-it-bnb-4bit

این مدل عضو بزرگ‌تر خانواده Gemma اسمت که مانند مدل ۶.۱.۴، Quantize شده و بسیار سبک‌تر شده است.

۲.۴ روش‌های ارزیابی

۱.۲.۴ سوالات چند گزینه‌ای

در تمامی مقالات ذکر شده در بخش ۲، یکی از روش‌های ارزیابی و مقایسه مدل‌ها، استفاده از سوالات چندگزینه‌ای و مقایسه دقت پاسخ‌دهی مدل‌ها با یکدیگر بود. در این پروژه نیز از همین روش به عنوان

معیار اصلی ارزیابی و مقایسه استفاده شده است. به این صورت که سوالات چندگزینه‌ای به مدل داده می‌شود و مدل پاسخ مورد نظر را در خروجی ارائه می‌دهد (نمونه‌ای از این فرآیند در جدول ۱.۴ آمده است). [۲۶]

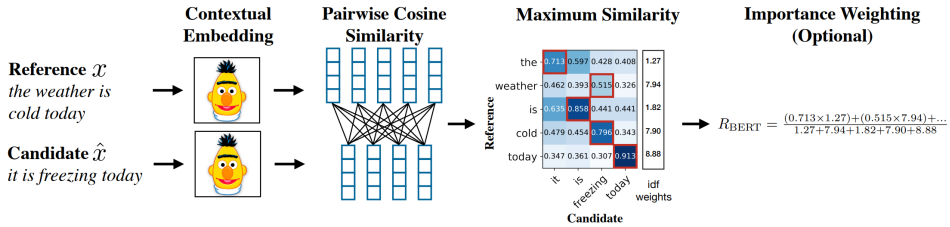
این آزمایش بر روی مدل‌های بخش ۱.۴ انجام شده و شامل استفاده از داده‌های انگلیسی و ترجمه‌شده فارسی این داده‌ها بود. نتایج به دست آمده در جدول ۲.۴ ارائه شده است.

۲.۲.۴ BERTScore

BERTSCORE یک معیار ارزیابی برای تولید متن است که با استفاده از مدل‌های از پیش آموزش دیده مانند BERT ایجاد شده و به مقایسه جملات کاندید و مرجع می‌پردازد. این معیار، برخلاف روش‌های سنتی مانند BLEU و METEOR، از شباهت کسینوسی میان بردارهای معنایی توکن‌ها استفاده می‌کند و بدین ترتیب می‌تواند وابستگی‌های طولانی را بهتر شناسایی کند. هدف اصلی BERTSCORE ایجاد یک معیار دقیق‌تر و معنایی‌تر برای ارزیابی تولید متن، به‌ویژه در وظایفی مانند ترجمه ماشینی بوده است.

معیارهای سنتی مانند BLEU، با تکیه بر تطابق n-gram، به سادگی تعداد تکرار کلمات مشابه را شمارش می‌کنند و معنای دقیق یا روابط پیچیده میان کلمات را نادیده می‌گیرند. این محدودیت‌ها به ویژه در مواردی که جملات کاندید و مرجع دارای ساختارهای متفاوت اما معنای آنها مشابه هستند، مشکل‌ساز می‌شود. در METEOR با اضافه‌کردن تطابق مترادف‌ها و ریشه‌های کلمات، تلاش کرده‌اند این مشکل را حل کنند، اما همچنان به منابع بیرونی وابسته است و در برخی زبان‌ها عملکرد محدودی دارد. در مقابل، BERTSCORE، با استفاده از جاسازی‌های زمینه‌ای که اطلاعات معنایی و ساختاری جمله را ثبت می‌کنند، یک رویکرد مستقل از ابزارهای بیرونی و مناسب برای زبان‌های مختلف ارائه می‌دهد.

نحوه کارکرد BERTSCORE به گونه‌ای طراحی شده که معنای هر توکن را با در نظر گرفتن زمینه کلی جمله استخراج می‌کند. این معیار ابتدا جمله مرجع و کاندید را به بردارهای جاسازی‌شده تبدیل می‌کند. سپس یک ماتریس شباهت کسینوسی بین تمام توکن‌های این دو جمله ایجاد می‌شود. در این ماتریس، هر سلول نشان‌دهنده شباهت معنایی میان یک توکن از جمله مرجع و یک توکن از جمله کاندید است. برای تطابق توکن‌ها، از یک الگوریتم تطابق حریصانه استفاده می‌شود که بیشترین شباهت برای هر توکن را انتخاب می‌کند. در نهایت، میانگین شباهت‌های انتخاب‌شده محاسبه شده و با بازخوانی (R_{BERT})، دقت (P_{BERT}) و F_1 ارائه می‌شود. مثال کارکرد آن را در تصویر ۱.۴ شبیه سازی شده است.



شکل ۱.۴: شبیه سازی نحوه کارکرد BERTSCORE

یکی از ویژگی‌های کلیدی BERTSCORE، توانایی آن در ارزیابی دقیق جملاتی است که به لحاظ ساختاری متفاوت اما از نظر معنایی مشابه هستند. برای مثال، در جمله مرجع "the weather is cold today" و جمله کاندید "it is freezing today"، کلماتی مانند "cold" و "freezing" به درستی تطابق داده می‌شوند، زیرا جاسازی‌های زمینه‌ای معنای مشابه آن‌ها را ثبت کرده‌اند. چنین قابلیتی در معیارهایی مانند BLEU و ROUGE وجود ندارد، زیرا این معیارها تنها به تطابق دقیق کلمات تکیه دارند. [۲۷]

۳.۲.۴ Hallucination

مدل HHEM-2.1-Open که توسط Vectara توسعه یافته است، برای شناسایی و ارزیابی توهمات در مدل‌های زبانی بزرگ طراحی شده است. این مدل به‌طور ویژه برای کاربردهایی مانند تولید متن بر اساس بازیابی اطلاعات مفید است، جایی که مدل‌های زبانی باید خلاصه‌هایی سازگار با اطلاعات منبع ارائه دهند. HHEM-2.1-Open با قابلیت ارزیابی دقیق و سریع، می‌تواند میزان نزدیکی متون تولیدشده را با متون اصلی مقایسه و نرخ توهم مدل را اندازه‌گیری کند. نسخه جدید این مدل نسبت به نسخه‌های قبلی و حتی مدل‌های پیشرفته‌ای مانند GPT-3.5-Turbo و GPT-4 عملکرد بهتری ارائه می‌دهد. یکی از مزایای کلیدی این مدل کارایی بالای آن است؛ به‌طوری که بر روی سخت‌افزارهای معمولی اجرا شده و با استفاده از حافظه کمی (کمتر از ۶۰۰ مگابایت)، ورودی‌هایی با ۲۰۰۰ توکن را در حدود ۵.۱ ثانیه پردازش می‌کند. HHEM-2.1-Open به‌عنوان یک مدل طبقه‌بندی توالی، ورودی‌ها را پردازش کرده و امتیازی بین ۰ تا ۱ ارائه می‌دهد؛ عدد ۰ نشان‌دهنده عدم توهم و عدد ۱ نشان‌دهنده توهم کامل است. این مدل نه تنها در تشخیص توهمات تولید متن کاربرد دارد. روش استفاده از این مدل را در جدول ۳.۴ مشاهده می‌کنید. [۲۸]

جدول ۱.۴: ارزیابی با سوالات چندگزینه‌ای

Input →	A mother with a 12 month old child goes to the nursing consultation for the administration of the MMR vaccine. In the consultation, the mother reports that she believes that the child has a certain intolerance to the egg, since sometimes after eating there are slight skin rashes that could be related to the intake. Taking into account all of the above, what would be the action we should take? A: Delay vaccination until the child improves egg tolerance. B: Administer, in a normal way, the MMR vaccine. C: Ask for skin allergy tests, and we will only administer the vaccine in case of a negative result of them. D: Inform the mother that currently the MMR vaccine is not grown on chicken-derived fibroblasts but that, even so, a skin allergy test will be requested before the administration of the vaccine.
Generated output →	B
Input →	A 22-year-old woman presents to her primary care physician in April for seasonal allergies. She has suffered from seasonal allergies for the past 2 years and takes diphenhydramine as needed when her symptoms worsen. She has not yet seen a physician for her allergies. She reports that diphenhydramine has been helpful in controlling her symptoms, but she does not like feeling drowsy from the medication. Her past medical history is also notable for well-controlled asthma. She uses an albuterol inhaler on an as-needed basis. She smokes marijuana daily. Her temperature is 99.2°F (37.3°C), blood pressure is 120/70 mmHg, pulse is 76/min, and respirations are 16/min. She has a prominent nasal crease. Her nasal turbinates are boggy and bluish-gray. She has copious thin and watery nasal mucus. The physician suggests replacing diphenhydramine with fexofenadine to improve her drowsiness. What characteristic of fexodenadine allows it to be less sedating than diphenhydramine? A: Alpha-adrenergic antagonism B: Beta-adrenergic antagonism C: Relative lipophobicity D: Serotonergic antagonism
Generated output →	C

جدول ۲.۴: نتایج ارزیابی مدل‌های فارسی زبان در سوالات چندگزینه‌ای

LLM	Language	CareQA	HeadQA-test	MedMCQA-val	MedQA4-test	MMLU-anatomy	MMLU-clinical-knowledge	MMLU-college-medicine	MMLU-medical-genetics	MMLU-professional-medicine	Avg.
aya-23-8B (4.1.1)	English	35.59 ± 0.67	37.21 ± 0.96	31.52 ± 0.74	31.62 ± 1.31	39.26 ± 4.21	41.77 ± 3.13	40.41 ± 4.75	40.40 ± 4.96	34.83 ± 2.92	36.96
	Persian	35.59 ± 0.67	37.21 ± 0.96	31.52 ± 0.74	31.62 ± 1.31	39.26 ± 4.21	41.77 ± 3.13	40.41 ± 4.75	40.40 ± 4.96	34.83 ± 2.92	36.96
aya-expanse-8b (4.1.2)	English	43.28 ± 0.69	44.67 ± 0.99	34.46 ± 0.75	34.69 ± 1.34	44.44 ± 4.29	51.81 ± 3.17	43.15 ± 3.11	42.42 ± 4.99	44.57 ± 3.05	42.61
	Persian	43.28 ± 0.69	44.67 ± 0.99	34.46 ± 0.75	34.69 ± 1.34	44.44 ± 4.29	51.81 ± 3.17	43.15 ± 3.11	42.42 ± 4.99	44.57 ± 3.05	42.61
gemma-2-2b-it (4.1.3)	English	36.15 ± 0.67	37.72 ± 0.97	31.07 ± 0.73	29.12 ± 1.28	31.85 ± 4.02	41.77 ± 3.13	36.30 ± 3.99	37.37 ± 4.89	32.21 ± 2.87	34.84
	Persian	36.15 ± 0.67	37.72 ± 0.97	31.07 ± 0.73	29.12 ± 1.28	31.85 ± 4.02	41.77 ± 3.13	36.30 ± 3.99	37.37 ± 4.89	32.21 ± 2.87	34.84
c4ai-command-r7b (4.1.4)	English	$\pm$	$\pm$	$\pm$	$\pm$	$\pm$	$\pm$	$\pm$	$\pm$	$\pm$	
	Persian	$\pm$	$\pm$	$\pm$	$\pm$	$\pm$	$\pm$	$\pm$	$\pm$	$\pm$	
gemma-2-9b-it (4.1.5)	English	57.62 ± 0.69	$58.00 \pm 0,99$	41.93 ± 0.78	46.38 ± 1.41	52.59 ± 4.31	61.85 ± 3.08	63.01 ± 4.01	60.61 ± 4.94	62.92 ± 2.96	56.10
	Persian	57.62 ± 0.69	$58.00 \pm 0,99$	41.93 ± 0.78	46.38 ± 1.41	52.59 ± 4.31	61.85 ± 3.08	63.01 ± 4.01	60.61 ± 4.94	62.92 ± 2.96	56.10
gemma-2-9b-it-bnb-4bit (4.1.6)	English	55.12 ± 0.69	57.88 ± 0.99	42.08 ± 0.78	45.66 ± 1.40	51.11 ± 4.32	60.64 ± 3.10	62.33 ± 4.02	60.61 ± 4.94	60.30 ± 3.00	55.08
	Persian	55.12 ± 0.69	57.88 ± 0.99	42.08 ± 0.78	45.66 ± 1.40	51.11 ± 4.32	60.64 ± 3.10	62.33 ± 4.02	60.61 ± 4.94	60.30 ± 3.00	55.08
gemma-2-27b-it-bnb-4bit (4.1.7)	English	64.70 ± 0.67	65.03 ± 0.95	45.75 ± 0.79	52.74 ± 1.41	58.52 ± 4.26	67.07 ± 2.98	65.75 ± 3.94	74.75 ± 4.39	67.79 ± 2.87	62.46
	Persian	64.70 ± 0.67	65.03 ± 0.95	45.75 ± 0.79	52.74 ± 1.41	58.52 ± 4.26	67.07 ± 2.98	65.75 ± 3.94	74.75 ± 4.39	67.79 ± 2.87	62.46

جدول ۳.۴: محاسبه نرخ توهم (Hallucination) دو متن.

Input 1	Input 2	Output (Result)
The capital of France is Berlin.	The capital of France is Paris.	0.0111
I am in California	I am in United States.	0.6474
I am in United States	I am in California.	0.1290
A person on a horse jumps over a broken down airplane.	A person is outdoors, on a horse.	0.8969
A boy is jumping on skateboard in the middle of a red bridge.	The boy skates down the sidewalk on a red bridge	0.1846
A man with blond-hair, and a brown shirt drinking out of a public water fountain.	A blond man wearing a brown shirt is reading a book.	0.0050
Mark Wahlberg was a fan of Manny.	Manny was a fan of Mark Wahlberg.	0.0543

فصل ۵

ارتقای دانش داخلی

۱.۵ کتابخوانه‌ها

۱.۱.۵ HuggingFace Transformers

کتابخانه HuggingFace Transformers یکی از محبوب‌ترین ابزارهای متن‌باز در حوزه یادگیری ماشین و پردازش زبان طبیعی (NLP) است که امکاناتی جامع برای استفاده و آموزش از مدل‌ها فراهم می‌کند. در تنظیم دقیق مدل‌های زبانی پکیج Transformers به عنوان یک پکیج پایه استفاده می‌شود.

۲.۱.۵ Llama Factory

LLaMA-Factory یک پکیج متن‌باز است که برای مدیریت، تنظیم دقیق، و بهینه‌سازی مدل‌های زبان بزرگ طراحی شده است. این ابزار پیشرفته، امکاناتی برای آموزش مدل‌ها با استفاده از روش‌های مدرن مانند LoRA[1] فراهم می‌کند که کارایی و استفاده از منابع سخت‌افزاری را بهبود می‌بخشد. LLaMA-Factory قابلیت مدیریت فرآیندهای پیچیده‌ای مانند تولید مبتنی بر بازیابی[2] و استفاده ترکیبی از ابزارها در چندین مرحله را ارائه می‌دهد، که این ویژگی‌ها برای حل مسائل چالش‌برانگیز و چندمرحله‌ای کاربردی هستند. این پکیج با ادغام کامل با PyTorch، امکاناتی برای توزیع محاسبات و مدیریت حافظه در آموزش مدل‌های بزرگ فراهم می‌کند، که برای کاربرانی با منابع سخت‌افزاری محدود نیز مفید است. همچنین، ابزارهایی برای پیش‌پردازش داده، مدیریت توکنایزرها، و ارزیابی مدل‌ها ارائه می‌دهد که فرآیند آماده‌سازی و بهبود مدل را تسریع می‌بخشند. [۲۹]

۳.۱.۵ Axolotl

پکیج Axolotl یک ابزار قدرتمند و انعطاف‌پذیر برای تنظیم دقیق مدل‌های زبان بزرگ با تمرکز بر سادگی، مقیاس‌پذیری، و سفارشی‌سازی است. این پکیج به ویژه برای کار با مدل‌های مبتنی بر فریم‌ورک‌های Hugging Face Transformers طراحی شده و از روش‌های مدرن مانند LoRA[3] و QLoRA[4] پشتیبانی می‌کند که به کاربران امکان می‌دهد مدل‌های بزرگ را با استفاده از منابع سخت‌افزاری محدود

[1] Low-Rank Adaptation
[2] RAG
[3] Low-Rank Adaptation
[4] Quantized LoRA

آموزش دهند. Axolotl با ارائه قابلیت‌هایی مانند مدیریت داده، پیش‌پردازش، و تنظیمات سفارشی برای مدل‌ها، امکان اجرای فرآیندهای پیچیده تنظیم دقیق را بدون نیاز به کدنویسی‌های سنگین فراهم می‌کند. این پکیج همچنین ابزارهایی برای ارزیابی مدل‌ها و تحلیل نتایج ارائه می‌دهد و از distributed scaling برای اجرای مدل‌ها در محیط‌های مختلف پشتیبانی می‌کند.

۴.۱.۵ Torch XLA

تنظیم دقیق مدل‌ها با استفاده از Torch XLA شامل استفاده از شتاب‌دهنده‌های سخت‌افزاری مانند TPU[5] برای بهبود کارایی و سرعت در فرآیند آموزش مدل‌های یادگیری عمیق است. این روش از قدرت بالای محاسبات موازی در TPUها بهره می‌گیرد و با استفاده از XLA[6]، محاسبات سنگین را بهینه‌سازی و به سرعت اجرا می‌کند. ابتدا مدل و داده‌ها به دستگاه‌های TPU منتقل می‌شوند، جایی که توزیع داده‌ها میان هسته‌های متعدد TPU برای آموزش موازی انجام می‌گیرد. Torch XLAفرآیند همگام‌سازی بین گره‌های توزیع‌شده را مدیریت می‌کند و از تأخیرهای ارتباطی جلوگیری می‌کند. یکی از ویژگی‌های کلیدی این روش، پشتیبانی از Mixed Precision Training است که با استفاده از داده‌های float16 به جای float32، حافظه کمتری مصرف می‌کند و سرعت محاسبات را افزایش می‌دهد. این روش با فراهم کردن ابزارهایی برای پروفایلینگ و دیباگینگ، امکان بهینه‌سازی مدل‌ها را ساده می‌کند و برای تنظیم دقیق مدل‌های بزرگ، به ویژه در کاربردهایی مانند پردازش زبان طبیعی ایده‌آل است.

این پکیج در GitHub به آدرس https://github.com/axolotl-ai-cloud/axolotl موجود است.

۵.۱.۵ NVIDIA NeMo

NVIDIA NeMo یک ابزار قدرتمند و انعطاف‌پذیر برای توسعه مدل‌های زبانی بزرگ و پیچیده است که به محققان و توسعه‌دهندگان اجازه می‌دهد تا به سرعت و به صورت کارآمد مدل‌های سفارشی خود را برای طیف گسترده‌ای از وظایف ایجاد کنند. این چارچوب با ارائه مجموعه‌ای غنی از مدل‌های از پیش آموزش دیده، ابزارهای آماده‌سازی داده و تکنیک‌های بهینه‌سازی، فرآیند توسعه مدل را تسهیل می‌کند. با استفاده از NeMo، توسعه‌دهندگان می‌توانند به سرعت مدل‌های زبانی را برای وظایفی مانند تولید متن، ترجمه ماشینی، خلاصه‌سازی متن و تشخیص گفتار آموزش دهند. علاوه بر این، NeMo با سخت‌افزارهای قدرتمند NVIDIA به خوبی یکپارچه شده است و به این ترتیب به توسعه‌دهندگان اجازه می‌دهد تا از حداکثر توان محاسباتی برای آموزش و استنتاج مدل‌های خود استفاده کنند. به طور کلی، NeMo یک ابزار ارزشمند برای توسعه مدل‌های زبانی پیشرفته و کاربردی است.

این پکیج در GitHub به آدرس https://github.com/NVIDIA/NeMo موجود است.

۶.۱.۵ Xtunner

پکیج XTuner که در مخزن GitHub به آدرس https://github.com/InternLM/xtuner/ ارائه شده است، ابزاری پیشرفته برای تنظیم دقیق مدل‌های زبان بزرگ با تأکید بر بهینه‌سازی و کاهش هزینه‌های محاسباتی است. این پکیج با پشتیبانی از روش‌های مدرن مانند LoRA و Prefix Tuning، امکان سفارشی‌سازی مدل‌های پیش‌آموزش‌دیده را برای وظایف خاص فراهم می‌کند. XTuner برای ادغام با مدل‌ها و ابزارهای موجود در Hugging Face Transformers طراحی شده است. از ویژگی‌های بارز این پکیج می‌توان به انعطاف‌پذیری بالا در تنظیمات، پشتیبانی از آموزش توزیع‌شده، و سازگاری با منابع

[5] Tensor Processing Units
[6] Accelerated Linear Algebra

سخت‌افزاری محدود اشاره کرد. همچنین، XTuner ابزارهای پیشرفته‌ای برای مدیریت داده، تنظیم‌های دقیق پارامترها، و ارزیابی عملکرد مدل‌ها ارائه می‌دهد. این پکیج با استفاده از الگوریتم‌های بهینه‌سازی و معماری‌های کارآمد، امکان کاهش تعداد پارامترهای آموزش‌دیده و حفظ کیفیت مدل را فراهم می‌کند. [۳۰]

۷.۱.۵ Unslot

این پلتفرم با هدف تسریع و ساده‌سازی فرآیندهای مرتبط با مدل‌های زبان بزرگ طراحی شده است و امکاناتی برای تنظیم دقیق، استقرار، و مدیریت این مدل‌ها فراهم می‌کند. Unsloth کاربران را قادر می‌سازد تا بدون نیاز به دانش عمیق، مدل‌های از پیش آموزش‌دیده را برای وظایف خاص خود بهینه‌سازی کنند. این مستندات شامل توضیحات دقیقی درباره تنظیمات فنی، ادغام API، و روش‌های کار با ابزارهایی مانند LoRA برای کاهش هزینه‌های محاسباتی و مصرف منابع است. همچنین، Unsloth از ارزیابی مدل‌ها با متریک‌های استاندارد و نظارت بر عملکرد در طول زمان پشتیبانی می‌کند. مستندات Unsloth همچنین شامل راهنماهایی برای رفع اشکال و بهترین شیوه‌ها برای بهره‌وری بیشتر در استفاده از مدل‌های هوش مصنوعی است.

مستندات Unsloth AI در آدرس docs.unsloth.ai قرار دارد، راهنمای جامعی برای استفاده از پلتفرم Unsloth ارائه می‌دهد.

در این پروژه از این پکیج استفاده می‌کنیم چون علاوه بر سادگی در استفاده تضمین می‌کند در بدترین حالت آموزش مدل با سرعت دو برابر انجام شود و از سوی دیگر قابلیت Quantization در ابعاد مختلف و ایجاد خروجی قابل اجرا در ابزار Ollama را یکجا دارد.

۲.۵ Supervised Fine-Tuning

۱.۲.۵ روش‌ها

- LoRA

LoRA[۷] روشی نوآورانه برای تطبیق مدل‌های زبانی پیش‌تربیت‌شده بزرگ به وظایف پایین‌دستی است. این روش با کاهش تعداد پارامترهای قابل تنظیم، باعث بهبود کارایی محاسباتی و حافظه شده و در عین حال کیفیت مدل را حفظ می‌کند. ایده اصلی LoRA این است که به‌جای به‌روزرسانی مستقیم تمامی وزن‌های مدل، تغییرات وزن‌ها را در قالب ماتریس‌هایی با رتبه پایین (ΔW) مدل‌سازی و بهینه‌سازی کند.

در LoRA، فرض بر این است که تغییرات مورد نیاز در وزن‌های مدل (ΔW) برای تطبیق با یک وظیفه پایین‌دستی، در یک زیرفضای کوچک‌تر نسبت به وزن‌های اصلی قرار دارد. برای پیاده‌سازی این ایده، به‌روزرسانی وزن‌ها به‌صورت زیر مدل‌سازی می‌شود:

$$BA + W_0 = \Delta W + W_0$$

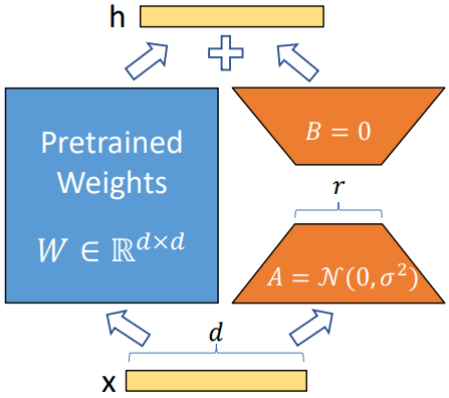
که در آن:

- W_0: ماتریس وزن پیش‌تربیت‌شده و ثابت مدل است.

[7] Low-Rank Adaptation

- A و B: ماتریس‌های قابل تنظیم با ابعاد کوچک‌تر (رتبه پایین) هستند، به‌طوری‌که $B \in \mathbb{R}^{d\times r}, \quad A \in \mathbb{R}^{r\times k}, \quad r \ll \min(d,k)$
- r: رتبه LoRA، که به‌طور قابل توجهی کوچک‌تر از ابعاد وزن اصلی انتخاب می‌شود.

به این ترتیب، به‌جای بهینه‌سازی مستقیم وزن‌های W_0 ، تنها ماتریس‌های A و B که تغییرات وزن را مدل‌سازی می‌کنند، آموزش داده می‌شوند. این امر باعث کاهش تعداد پارامترهای قابل تنظیم می‌شود و حافظه و زمان محاسباتی مورد نیاز را کاهش می‌دهد. (تصویر ۱.۵)



شکل ۱.۵: عملکرد LoRA

در فرآیند آموزش، وزن‌های پیش‌تربیت‌شده W_0 ثابت نگه داشته می‌شوند. ماتریس‌های A و B با مقداردهی اولیه مناسب (صفر برای B و مقادیر تصادفی برای B بهینه‌سازی می‌شوند. برای بهینه‌سازی تغییرات وزن ($BA = \Delta W$)، یک ضریب مقیاس‌بندی ($\frac{\alpha}{r}$) نیز اعمال می‌شود که مقدار آن به‌طور پیش‌فرض متناسب با رتبه LoRA تنظیم می‌شود. این طراحی باعث می‌شود که تغییرات اولیه کوچک باشند و روند بهینه‌سازی پایدارتر شود.

هنگام استنتاج، ماتریس‌های به‌روزرسانی‌شده A و B می‌توانند به صورت صریح با وزن‌های اصلی W_0 ترکیب شوند تا وزن نهایی $W = W_0 + \Delta W$ محاسبه شود. این فرآیند باعث می‌شود که مدل بتواند بدون هیچ تأخیری در زمان استنتاج، مشابه مدل‌های تنظیم‌شده کامل عمل کند. این ویژگی LoRA را برای استفاده در کاربردهای عملی، به‌ویژه در محیط‌هایی با محدودیت سخت‌افزاری، بسیار ارزشمند می‌کند.

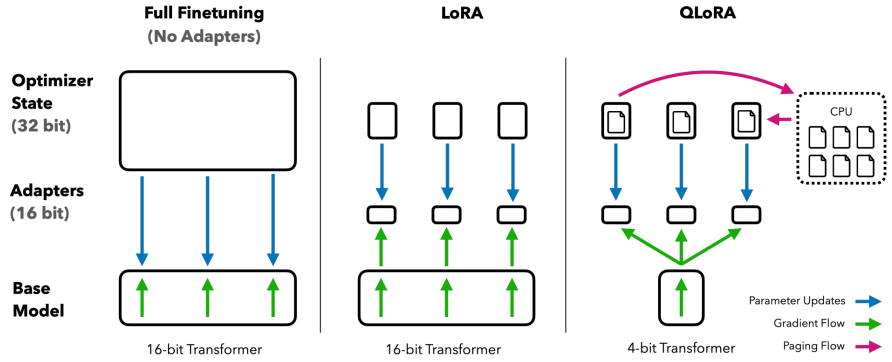
LoRA چندین مزیت کلیدی دارد. نخست، این روش تعداد پارامترهای قابل تنظیم را به طور چشمگیری کاهش می‌دهد، به‌طوری‌که در مدل‌های بسیار بزرگ مانند GPT-3، تنها ۰.۱۰ درصد از کل پارامترها نیاز به تنظیم دارند. دوم، این روش حافظه و سخت‌افزار مورد نیاز را کاهش می‌دهد؛ زیرا نیازی به محاسبه گرادیان برای تمام وزن‌ها وجود ندارد. علاوه بر این، LoRA تأخیری در زمان استنتاج ایجاد نمی‌کند، چرا که وزن‌های به‌روزرسانی‌شده می‌توانند مستقیماً با وزن‌های اصلی ادغام شوند. همچنین، قابلیت جابه‌جایی سریع بین وظایف مختلف، از دیگر مزایای این روش است.

با وجود مزایای LoRA، چالش‌هایی نیز وجود دارد. برای مثال، در مواردی که نیاز به پردازش هم‌زمان ورودی‌های چندوظیفه‌ای وجود دارد، اجرای LoRA ممکن است دشوار باشد، مگر اینکه

وزن‌ها به صورت پویا مدیریت شوند. همچنین، اگرچه LoRA عملکرد بالایی با رتبه‌های کوچک ارائه می‌دهد، انتخاب رتبه مناسب r برای برخی وظایف ممکن است نیازمند آزمون و خطای بیشتری باشد. [۳۱]

- QLoRA

QLORA به معرفی روشی نوآورانه برای تنظیم دقیق مدل‌های زبان بزرگ‌می‌پردازد که هدف اصلی آن کاهش مصرف حافظه و منابع سخت‌افزاری است. این روش با استفاده از کوانتسازی ۴ بیتی و LoRA، امکان تنظیم دقیق مدل‌هایی با اندازه‌های بسیار بزرگ (تا ۶۵ میلیارد پارامتر) را روی سخت‌افزارهای مصرفی و حرفه‌ای فراهم می‌کند. روش QLORA بدون کاهش عملکرد، مصرف حافظه را به‌طور قابل‌توجهی کاهش می‌دهد و با استفاده از تکنیک‌هایی مانند NF4[۸]، کوانت‌سازی دوگانه و بهینه‌سازهای صفحه‌بندی‌شده، کارایی خود را بهبود می‌بخشد. در تصویر ۲.۵ تفاوت Full Fine-tuning با روش‌های LoRA و QLoRA را می‌بینیم که در QLoRA از paged optimizer استفاده شده است تا حافظه بهتر مدیریت شود.



شکل ۲.۵: مقایسه Full Fine-tuning با روش‌های LoRA و QLoRA

نتایج این مقاله نشان می‌دهد که QLORA در بنچمارک‌های استاندارد مانند MMLU و Vicuna عملکردی معادل یا بهتر از تنظیم دقیق کامل ۱۶ بیتی دارد. این روش، داده‌های ذخیره‌سازی ۴ بیتی را به نوع داده‌های محاسباتی ۱۶ بیتی تبدیل می‌کند تا دقت محاسبات حفظ شود و گرادیان‌ها فقط برای پارامترهای LoRA محاسبه شوند. بررسی کیفی نشان داد که مدل تنظیم‌شده با QLORA در پاسخ به سؤالات عمومی بسیار دقیق است، اما در مواجهه با سؤالات پیچیده‌تر ممکن است پاسخ‌های اشتباه تولید کند.

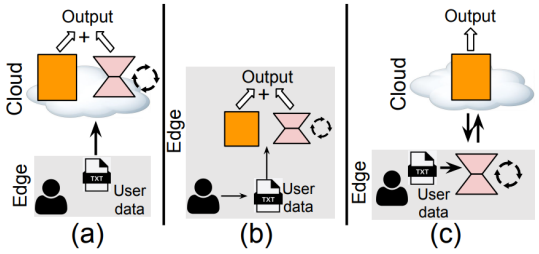
از محدودیت‌های این روش، عدم ارزیابی در مقیاس‌های بسیار بزرگ‌تر و بررسی‌های محدود روی سوگیری‌های اجتماعی است. با این وجود، QLORA ابزار مهمی برای افزایش دسترسی به تنظیم دقیق مدل‌های زبانی است، به‌ویژه برای پژوهشگرانی که منابع محدودی دارند. همچنین، این روش می‌تواند تنظیم دقیق مدل‌ها را بر روی دستگاه‌هایی با منابع محدود امکان‌پذیر کند. [۳۲]

- DLoRA

[8] NormalFloat 4-bit

مدل‌های زبانی بزرگ به دلیل قابلیت‌های خود در انجام وظایف پیچیده پردازش زبان طبیعی (مانند ترجمه، خلاصه‌سازی و تولید متن) به ابزارهای کلیدی در حوزه هوش مصنوعی تبدیل شده‌اند. با این حال، بهینه‌سازی این مدل‌ها برای داده‌ها و وظایف خاص کاربران، نیازمند تنظیم دقیق پارامترها است. این فرآیند با چالش‌هایی نظیر هزینه‌های بالای محاسباتی، نگرانی‌های حریم خصوصی، و مقیاس‌پذیری مواجه است.

برای حل این مشکلات، مقاله راهکاری به نام DLoRA پیشنهاد می‌دهد که یک چارچوب توزیع‌شده برای تنظیم دقیق پارامترهاست. این چارچوب عملیات تنظیم دقیق را میان سرورهای ابری و دستگاه‌های کاربران توزیع می‌کند. داده‌های کاربران به صورت محلی در دستگاه‌های آن‌ها پردازش شده و تنها اطلاعات غیرحساس، مانند نتایج Embedding به سرور ارسال می‌شود. این رویکرد ضمن کاهش خطرات حریم خصوصی، امکان تنظیم دقیق مدل‌ها را حتی در دستگاه‌هایی با منابع محدود فراهم می‌کند. (تصویر ۳.۵)



شکل ۳.۵: (a) راهکار فقط ابری. (b) راهکار فقط لبه‌ای. (c) طرح DLoRA. پارامترهای ثابت و قابل یادگیری به ترتیب با رنگ نارنجی و قرمز نشان داده شده‌اند.

یکی از نوآوری‌های اصلی مقاله، الگوریتم KR[9] است. این الگوریتم دو مکانیسم اصلی را معرفی می‌کند: در مرحله اول، ماژول‌هایی از مدل که تغییرات ناچیزی در طی فرآیند تنظیم دقیق دارند شناسایی و به حالت غیرفعال درمی‌آیند تا از بار محاسباتی کاسته شود. این فرآیند که به نام Early-Kill شناخته می‌شود، باعث کاهش هزینه‌های ارتباطی و محاسباتی می‌شود. در مرحله دوم، الگوریتم به صورت پویا ماژول‌هایی را که در مراحل بعدی ممکن است اهمیت پیدا کنند، دوباره فعال می‌کند. این مرحله با نام Revival شناخته می‌شود و دقت کلی مدل را حفظ کرده یا حتی بهبود می‌بخشد.

ارزیابی‌ها نشان داده‌اند که DLoRA و الگوریتم KR نه‌تنها هزینه‌های محاسباتی را به میزان ۸۲٪ و حجم ارتباطات را به میزان ۵٪.۸۷ کاهش می‌دهند، بلکه دقت مدل را نیز در بسیاری از وظایف حفظ یا بهبود می‌بخشند. این نتایج در مقایسه با روش‌های پایه مانند FT[10] و روش‌های فشرده‌سازی مدل‌ها مانند SparseGPT و Wanda، عملکرد برتری را نشان می‌دهد.

DLoRA همچنین قابلیت مقیاس‌پذیری بالایی دارد و می‌تواند با افزایش تعداد کاربران یا داده‌ها به راحتی سازگار شود. با توجه به اینکه داده‌های خام کاربران در دستگاه‌های آن‌ها باقی می‌ماند، این چارچوب نگرانی‌های مرتبط با حریم خصوصی را برطرف کرده و امنیت داده‌ها را تضمین می‌کند.

[9] Kill and Revive
[10] Fully-Tune

در مجموع، مقاله نشان می‌دهد که DLoRA می‌تواند به عنوان راهکاری مؤثر و کارآمد برای تنظیم دقیق مدل‌های زبانی بزرگ در محیط‌های توزیع‌شده استفاده شود. این چارچوب با کاهش هزینه‌ها، حفظ دقت، و رفع نگرانی‌های حریم خصوصی، گامی مهم در جهت کاربرد عملی مدل‌های زبانی بزرگ در مقیاس وسیع است. [۳۳]

- روش‌های دیگر

روش‌های دیگری نیز مانند روش‌های:

- LoHa
- LoKr
- adaLoRa
- Prefix-tuning
- OLoRA
- LoftD
- PiSSA
- و روش‌های دیگری

وجود دارند ولی ما در این پروژه آنها را بررسی نمی‌کنیم.

۲.۲.۵ گزارش Supervised Fine-Tuning مدل

شامل کانفیگ‌ها، دیتاست‌ها، نمودارهای loss و ارزیابی

۳.۵ Alignment

۱.۳.۵ RLHF

روش ارائه‌شده در مقاله برای تنظیم دقیق مدل‌های زبانی با استفاده از یادگیری تقویتی مبتنی بر بازخورد انسانی (RLHF) شامل سه مرحله اصلی است که به صورت متوالی اجرا می‌شود. این روش با هدف همسوسازی مدل‌های زبانی با نیات انسانی طراحی شده است و از داده‌های جمع‌آوری‌شده توسط برچسب‌گذاران انسانی استفاده می‌کند.

در مرحله اول، داده‌های نمایشی جمع‌آوری می‌شوند. برچسب‌گذاران انسانی خروجی‌های مطلوبی را برای دستورات مختلف ارائه می‌دهند تا رفتار ایده‌آل مدل مشخص شود. سپس مدل GPT-3 از پیش‌آموزش‌دیده با استفاده از این داده‌ها از طریق یادگیری نظارت‌شده تنظیم دقیق می‌شود. این مرحله به مدل کمک می‌کند تا رفتارهای اولیه‌ای که با نیات انسانی همسو هستند، یاد بگیرد و در خروجی‌های خود اعمال کند.

در مرحله دوم، داده‌های مقایسه‌ای جمع‌آوری می‌شوند. برای هر دستور، مدل چندین خروجی مختلف تولید می‌کند و برچسب‌گذاران انسانی خروجی ترجیحی خود را انتخاب می‌کنند. این مقایسه‌ها به‌عنوان ورودی برای آموزش مدل پاداش استفاده می‌شوند. مدل پاداش یاد می‌گیرد که خروجی‌های ترجیحی انسانی را پیش‌بینی کند و از این اطلاعات برای ارزیابی و بهبود عملکرد مدل استفاده می‌شود.

در مرحله سوم، مدل نظارت‌شده با استفاده از مدل پاداش و الگوریتم PPO بهینه‌سازی می‌شود. مدل پاداش به‌عنوان سیگنال ارزیابی خروجی‌ها عمل می‌کند و الگوریتم PPO سیاست مدل را برای بهبود

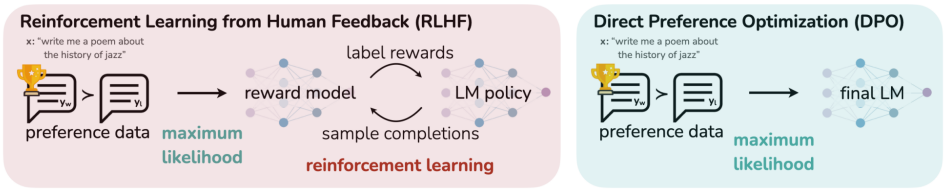
پاداش دریافتی تنظیم می‌کند. این مرحله به مدل امکان می‌دهد تا در محیط واقعی به‌صورت تقویتی یاد بگیرد و خروجی‌های خود را بهبود بخشد.

این سه مرحله به‌صورت تکراری اجرا می‌شوند تا مدل به تدریج به رفتار مطلوب نزدیک‌تر شود. داده‌های مقایسه‌ای جدید از سیاست‌های بهینه‌شده جمع‌آوری و مدل پاداش بازآموزی می‌شود. این روش ترکیبی از یادگیری نظارت‌شده و یادگیری تقویتی است که هم دقت و هم انعطاف‌پذیری مدل را افزایش می‌دهد و باعث می‌شود خروجی‌های تولیدشده نه‌تنها به دستورات کاربران پاسخ دهند، بلکه با محدودیت‌ها و معیارهای مشخص شده نیز سازگار باشند. [۳۴]

DPO ۲.۳.۵

DPO[11] یک روش ساده و موثر برای بهینه‌سازی سیاست مدل‌های زبانی با استفاده از ترجیحات انسانی است که برخلاف RLHF[12]، نیازی به یادگیری تقویتی ندارد. در DPO، فرآیند یادگیری به یک مسئله طبقه‌بندی کاهش می‌یابد، جایی که سیاست مدل مستقیماً برای افزایش احتمال پاسخ‌های ترجیحی و کاهش احتمال پاسخ‌های رد شده آموزش داده می‌شود.

در روش RLHF، مدل پاداش به‌طور جداگانه آموزش داده می‌شود تا ترجیحات انسانی را مدل‌سازی کند و سپس با استفاده از یادگیری تقویتی، سیاست مدل زبانی بهینه‌سازی می‌شود. در مقابل، DPO با استفاده از یک بازپارامترسازی خاص، تابع زیان را مستقیماً بر اساس سیاست مدل تعریف می‌کند. این بازپارامترسازی به ما اجازه می‌دهد که بدون نیاز به یادگیری صریح یک مدل پاداش یا انجام یادگیری تقویتی پیچیده، سیاست بهینه را استخراج کنیم. مقایسه این دو روش در جدول ۱.۵ و تصویر ۴.۵ انجام شده است. [۳۵]



شکل ۴.۵: مقایسه روش DPO با RLHF

مراحل اصلی روش DPO:

۱. نمونه‌برداری و برچسب‌گذاری داده‌ها: جفت‌هایی از پاسخ‌ها (y_l, y_w) برای هر پرامپت x از یک سیاست مرجع (π_{ref}) نمونه‌برداری می‌شوند. سپس برچسب‌گذاران انسانی پاسخ ترجیحی (y_w) و پاسخ رد شده (y_l) را مشخص می‌کنند.

۲. تعریف تابع زیان DPO: تابع زیان بر اساس مدل Bradley-Terry برای ترجیحات انسانی تعریف می‌شود. این تابع زیان به صورت زیر است:

$$\mathcal{L}_{DPO}(\pi_\theta; \pi_{ref}) = -\mathbb{E}_{(x,y_w,y_l)\sim D}\left[\log \sigma\left(\beta \log \frac{\pi_\theta(y_w|x)}{\pi_{ref}(y_w|x)} - \beta \log \frac{\pi_\theta(y_l|x)}{\pi_{ref}(y_l|x)}\right)\right]$$

[11] Direct Preference Optimization
[12] Reinforcement Learning from Human Feedback

در اینجا:

- $\pi_\theta(y \mid x)$: سیاست فعلی مدل
- $\pi_{ref}(y \mid x)$: سیاست مرجع
- β: پارامتری که میزان سخت‌گیری محدودیت KL را کنترل می‌کند.

۳. بهینه‌سازی سیاست مدل:

مدل زبانی (π_θ) برای کمینه‌سازی تابع زیان $\mathcal{L}_{DPO}$ آموزش داده می‌شود. گرادیان این تابع زیان به گونه‌ای عمل می‌کند که احتمال پاسخ‌های ترجیحی y_w را افزایش داده و احتمال پاسخ‌های رد شده y_l را کاهش دهد.

جدول ۱.۵: مقایسه روش DPO با RLHF

ویژگی	DPO	RLHF
پیچیدگی	ساده و بدون نیاز به یادگیری تقویتی	پیچیده؛ نیازمند دو مرحله (آموزش مدل پاداش و یادگیری تقویتی)
نیاز به مدل پاداش	بدون نیاز به مدل پاداش مجزا؛ تابع پاداش به‌طور ضمنی با سیاست مدل بازنمایی می‌شود	نیاز به یادگیری یک مدل پاداش صریح برای مدل‌سازی ترجیحات انسانی
تابع زیان	یک تابع زیان دوجمله‌ای (cross-entropy) ساده	ترکیبی از تابع پاداش و محدودیت KL در یادگیری تقویتی
پایداری	پایدار؛ به دلیل عدم نیاز به نمونه‌برداری از مدل حین آموزش	اغلب ناپایدار؛ به دلیل وابستگی به نمونه‌برداری از مدل و محاسبات پیچیده تابع پاداش
کارایی محاسباتی	بسیار کارآمد؛ نیازی به محاسبات سنگین یادگیری تقویتی ندارد	هزینه‌بر؛ شامل آموزش چند مدل زبانی و نمونه‌برداری‌های مکرر از مدل در حلقه یادگیری
انحراف KL	انحراف از سیاست مرجع به‌طور ذاتی در تابع زیان لحاظ شده است	به طور مستقیم از طریق محدودیت KL در فرآیند RLHF کنترل می‌شود
کاربرد در عمل	پیاده‌سازی آسان و سریع، حتی برای مدل‌های بزرگ	بهینه‌سازی پیچیده و نیازمند تنظیم دقیق ابرپارامترها
عملکرد تجربی	در آزمایش‌ها عملکردی مشابه یا بهتر از RLHF (PPO) داشت	عملکرد خوب، اما با هزینه محاسباتی بالا و ناپایداری احتمالی

۳.۳.۵ KTO

KTO یک روش جدید برای هم‌ترازی مدل‌های زبانی بزرگ است که از اصول تئوری چشم‌انداز کاهنمن و تورسکی بهره می‌برد. این روش مستقیماً مطلوبیت انسانی را به جای احتمال ترجیحات یا پاداش‌های مدل‌سازی‌شده بهینه می‌کند. KTO از سیگنال دودویی (خوب/بد) به‌جای ترجیحات جفتی یا مدل پاداش استفاده می‌کند و تابع زیان آن برای ادراک انسانی طراحی شده است. مقایسه این روش با دو روش قبل در جدول ۲.۵ آمده است. [۳۶]

ویژگی‌های اصلی KTO:

۱. تابع مطلوبیت مبتنی بر تئوری چشم‌انداز:
مطلوبیت یک خروجی با استفاده از تابع ارزش کاهنمن-تورسکی محاسبه می‌شود که حساسیت به سودها و زیان‌ها را با ضرایب جداگانه (λ_D و λ_U) و پارامتر ریسک‌گریزی (β) کنترل می‌کند.

۲. استفاده از سیگنال دودویی:
برخلاف روش‌های DPO و RLHF، KTO تنها به بازخورد ساده مطلوب یا نامطلوب نیاز دارد و نیازی به داده‌های پیچیده ترجیحی ندارد.

۳. تخمین نقطه مرجع با واگرایی KL:
یک نقطه مرجع z_0 برای ارزیابی کیفیت خروجی‌ها تعریف می‌شود که با استفاده از واگرایی KL محاسبه می‌شود و کیفیت نسبی خروجی‌ها را نسبت به مدل مرجع (π_{ref}) اندازه‌گیری می‌کند.

۴. مزیت در داده‌های نامتعادل:
KTO می‌تواند حتی با تعداد کمی از داده‌های مطلوب (در مقایسه با داده‌های نامطلوب) عملکرد مطلوبی ارائه دهد.

تابع KTO loss به شکل زیر تعریف می‌شود:

$$L_{KTO}(\pi_\theta, \pi_{ref}) = \mathbb{E}_{x,y\sim D}\left[\lambda_y - v(x,y)\right]$$

که در آن:

- $r_\theta(x,y) = \log\left(\frac{\pi_\theta(y|x)}{\pi_{ref}(y|x)}\right)$: نشان‌دهنده کیفیت خروجی y است.
- $v(x,y)$: تابع مطلوبیت که با توجه به خروجی مطلوب یا نامطلوب به صورت زیر تعریف می‌شود:

$$v(x,y) = \begin{cases} \lambda_D \cdot \sigma(\beta \cdot (r_\theta(x,y) - z_0)) & if: y \sim y_{desirable} \mid x \\ \lambda_U \cdot \sigma(\beta \cdot (z_0 - r_\theta(x,y))) & if: y \sim y_{undesirable} \mid x \end{cases}$$

- z_0: نقطه مرجع که کیفیت نسبی خروجی‌ها را تعیین می‌کند و با واگرایی KL محاسبه می‌شود:

$$z_0 = KL\left(\pi_\theta(y' \mid x) \,\|\, \pi_{ref}(y' \mid x)\right)$$

ORPO ۴.۳.۵

روش ORPO بر اساس استفاده از نسبت شانس[15] برای هم‌ترازی ترجیحات طراحی شده است. این روش برخلاف روش‌های پیچیده مانند RLHF یا DPO، نیازی به مدل مرجع یا مراحل چندگانه ندارد. ORPO تمام فرآیند هم‌ترازی ترجیحات را در یک مرحله انجام می‌دهد و تنها با اضافه‌کردن یک ترم جریمه به تابع خطای معمولی (Negative Log-Likelihood) عمل می‌کند. مقایسه آن با روش‌های DPO و RLHF در جدول ۳.۵ و تصور ۵.۵ قرار دارد. [۳۷]
اجزای اصلی ORPO:

[15] Odds Ratio

جدول ۲.۵: مقایسه روش‌های KTO، DPO و RLHF

ویژگی‌ها	KTO	DPO	RLHF
هدف بهینه‌سازی	مطلوبیت انسانی با استفاده از تابع ارزش کاهنمن-تورسکی	احتمال نسبی ترجیحات[۱۳]	یادگیری یک مدل پاداش و بهینه‌سازی آن با الگوریتم‌های RL
نوع داده موردنیاز	سیگنال دودویی (خوب/بد)	داده‌های ترجیحی جفتی ($y_w \succ y_l$)	داده‌های ترجیحی و مدل پاداش
پایداری و سرعت	پایدار و سریع به دلیل استفاده از Closed-form توابع	نسبتاً پایدار ولی به داده‌های ترجیحی وابسته	ناپایدار و کند به دلیل پیچیدگی الگوریتم‌های RL
تعامل با داده‌های نامتعادل	عملکرد مناسب حتی با داده‌های نامتعادل	حساس به تعادل داده‌های ترجیحی	حساس به تعادل داده و مستعد افت عملکرد در صورت وجود نویز یا داده‌های محدود
کاربرد در مدل‌های اولیه	می‌تواند بدون نیاز به تنظیم دقیق[۱۴] استفاده شود	نیاز به SFT برای دستیابی به عملکرد بهتر	نیاز شدید به SFT برای ایجاد مدل مرجع
سادگی پیاده‌سازی	ساده‌تر به دلیل عدم نیاز به یادگیری مدل پاداش و ترجیحات پیچیده	نسبتاً ساده، اما نیاز به داده‌های ترجیحی باکیفیت دارد	پیچیده به دلیل نیاز به یادگیری مدل پاداش و استفاده از الگوریتم‌های RL

۱. تابع خطای تنظیم دقیق (L_{SFT}):

این تابع به منظور افزایش احتمال تولید پاسخ‌های مطلوب توسط مدل استفاده می‌شود.

۲. تابع خطای نسبی نسبت شانس (L_{OR}):

این تابع تفاوت بین شانس تولید پاسخ انتخاب‌شده (y_w) و پاسخ ردشده (y_l) را افزایش می‌دهد. تابع کلی ORPO به‌صورت زیر تعریف می‌شود:

$$L_{ORPO} = \mathbb{E}_{(x,y_w,y_l)} \left[L_{SFT} + \lambda \cdot L_{OR} \right]$$

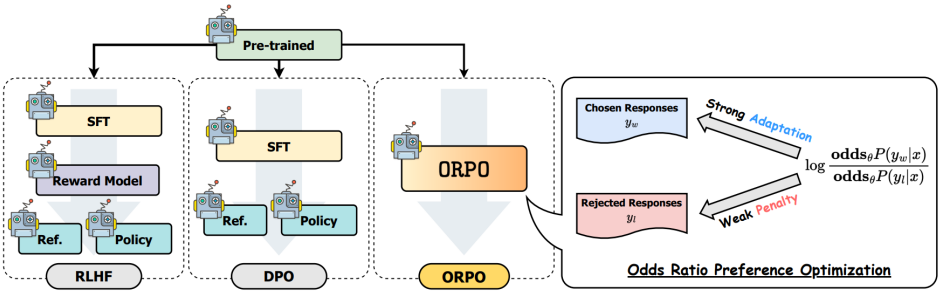
در این رابطه:

$$L_{OR} = -\log \sigma \left(\log \frac{odds_\theta(y_w|x)}{odds_\theta(y_l|x)} \right)$$

که در آن σ تابع سیگموید است و نسبت شانس ($odds_\theta$) احتمال تولید یک پاسخ مطلوب به یک پاسخ نامطلوب را نشان می‌دهد.

ORPO به‌صورت پویا شانس تولید پاسخ‌های نامطلوب را کاهش داده و شانس تولید پاسخ‌های مطلوب را تقویت می‌کند. این امر به مدل کمک می‌کند تا به تولید پاسخ‌های هماهنگ با ترجیحات انسانی هدایت شود.

مزایای ORPO:



شکل ۵.۵: ORPO، DPO و RLHF

- حذف نیاز به مدل مرجع: برخلاف روش‌های DPO و RLHF، ORPO تنها با استفاده از مدل تنظیم‌شدهSFT کار می‌کند و نیازی به مدل مرجع یا مدل پاداش ندارد.
- کاهش هزینه محاسباتی: این روش تنها به دو Forward Pass نیاز دارد، در حالی که روش‌های دیگر مانند RLHF و DPO به چهار مورد نیازمندند.
- یکپارچگی مراحل: ORPO فرآیندهای تنظیم دقیق نظارت‌شده و هم‌ترازی ترجیحات را به‌طور همزمان و یکپارچه انجام می‌دهد، که منجر به سادگی و کارایی بالاتر می‌شود.

جدول ۳.۵: جدول مقایسه ORPO، DPO و RLHF

ویژگی	ORPO	DPO	RLHF
نیاز به مدل مرجع	ندارد	دارد	دارد
تعداد مراحل	یک مرحله	دو مرحله (SFT + DPO)	سه مرحله (SFT + مدل پاداش + RLHF)
هزینه محاسباتی	کم	متوسط	بالا
پیچیدگی تنظیمات	کم	متوسط	بالا
مزایا	کارایی بالا، کاهش هزینه‌ها	کاهش مراحل نسبت به RLHF	تنظیم دقیق‌تر ترجیحات انسانی
معایب	به شانس متکی است	نیاز به مدل مرجع	پیچیدگی و هزینه بالا
کاربرد در مقیاس بالا	مناسب	مناسب	محدود به منابع بیشتر

۵.۳.۵ گزارش Alignment مدل

شامل کانفیگ‌ها، دیتاست‌ها، نمودارهای loss و ارزیابی

فصل ۶

ارتقای دانش خارجی

۱.۶ فریم‌ورک‌ها

۱.۱.۶ LangChain

کتابخانه LangChain مجموعه‌ای از ابزارهای پیشرفته برای ساخت و توسعه برنامه‌های هوش مصنوعی مبتنی بر مدل‌های زبان بزرگ ارائه می‌دهد. این ابزارها در حوزه‌های مختلف از مدیریت پرامپت‌ها تا ادغام داده‌های خارجی و ایجاد زنجیره‌های پردازشی به توسعه‌دهندگان کمک می‌کنند. در ادامه، جزئیات ابزارهای اصلی این کتابخانه آورده شده است:

۱. مدیریت پرامپت‌ها (Prompt Management)

این ابزارها به توسعه‌دهندگان امکان می‌دهند پرامپت‌ها را قالب‌بندی، ساختاربندی و مدیریت کنند. ابزارهای مدیریت پرامپت به گونه‌ای طراحی شده‌اند که بتوانید دستوراتی واضح، منسجم و مؤثر برای مدل‌های زبانی ایجاد کنید. این ویژگی به‌خصوص برای ایجاد پاسخ‌های دقیق‌تر و کاهش ابهامات مدل بسیار مفید است.

۲. زنجیره‌ها (Chains)

زنجیره‌ها هسته اصلی LangChain هستند و به شما این امکان را می‌دهند که چندین عملیات یا فراخوانی مدل را به صورت گام‌به‌گام ترکیب کنید. این ابزار برای انجام وظایف پیچیده مانند:

- سیستم‌های پرسش و پاسخ بر پایه متن
- ایجاد و تحلیل متن
- مدیریت فرآیندهای چندمرحله‌ای

بسیار مناسب است. به عنوان مثال، زنجیره‌ای می‌تواند شامل بازیابی اطلاعات از یک پایگاه داده، پردازش آن‌ها و سپس تولید پاسخ باشد.

۳. بازیاب‌ها (Retrievers)

بازیاب‌ها امکان دسترسی به داده‌های خارجی را فراهم می‌کنند. این داده‌ها می‌توانند شامل اسناد، پایگاه‌های داده یا محتوای آنلاین باشند. بازیاب‌ها همچنین قابلیت پردازش داده‌ها را برای آماده‌سازی اطلاعات برای مدل‌های زبانی فراهم می‌کنند.

این ابزار برای ساخت سیستم‌های پرسش و پاسخ مبتنی بر دانش، ادغام داده‌های شرکت و اتصال به منابع داده خارجی استفاده می‌شود.

۴. عامل‌ها (Agents)

Agents ابزارهایی هستند که به مدل‌های زبان بزرگ اجازه می‌دهند به صورت پویا و خودکار وظایف مختلف را مدیریت کنند. این ابزارها برخلاف زنجیره‌ها که مسیر از پیش تعریف‌شده دارند، به مدل امکان می‌دهند در زمان اجرا تصمیم بگیرد چه عملیاتی انجام دهد یا از چه ابزاری استفاده کند.

ویژگی‌های کلیدی عامل‌ها:

- دسترسی به ابزارها: توانایی استفاده از APIها، پایگاه‌های داده، موتورهای جستجو و ابزارهای خارجی.
- تصمیم‌گیری پویا: انتخاب مسیر و ابزار مناسب برای حل مشکلات در لحظه.
- مدیریت وظایف پیچیده: انجام چند مرحله پردازش یا ادغام اطلاعات از منابع مختلف.

Agents در وظایفی مانند پرسش و پاسخ پیشرفته، اتوماسیون فرآیندها، و تعامل با خدمات خارجی استفاده می‌شوند. آن‌ها ابزاری انعطاف‌پذیر برای توسعه سیستم‌های هوشمند و پویا هستند.

۵. حافظه (Memory)

قابلیت حافظه یکی از ویژگی‌های متمایز LangChain است که امکان ذخیره و یادآوری تعاملات گذشته را برای مدل فراهم می‌کند. این ابزار برای ساخت ربات‌های چت پیشرفته که باید مکالمات گذشته را به خاطر بسپارند و بر اساس آن‌ها پاسخ دهند، بسیار کاربردی است.

۶. ابزارهای اشکال‌زدایی و نظارت (LangSmith)

LangChain ابزاری به نام LangSmith ارائه می‌دهد که توسعه‌دهندگان می‌توانند با استفاده از آن عملکرد سیستم‌های خود را نظارت و مشکلات آن‌ها را رفع کنند. این ابزار به صورت گرافیکی اطلاعات مرتبط با زنجیره‌ها و پرامپت‌ها را نمایش می‌دهد و امکان بهینه‌سازی آن‌ها را فراهم می‌کند.

۷. ادغام‌پذیری بالا

LangChain به گونه‌ای طراحی شده که با ابزارهای مختلف از جمله Python، پایگاه‌های داده، و حتی منابع داده خصوصی به‌راحتی ادغام شود.

این ویژگی‌ها LangChain را به ابزاری قدرتمند و انعطاف‌پذیر برای ساخت برنامه‌های مبتنی بر هوش مصنوعی تبدیل کرده است.

۲.۱.۶ Llama-Index

LlamaIndex ، یک چارچوب منبع‌باز، ابزارهای متنوعی برای مدیریت، ایندکس، و بازیابی داده‌ها ارائه می‌دهد که امکان استفاده بهینه از مدل‌های زبان بزرگ را فراهم می‌کند. در ادامه ابزارها و ویژگی‌های کلیدی این کتابخانه بررسی شده است:

۱. مدیریت داده‌ها (Data Handling)

LlamaIndex امکان اتصال و پردازش داده‌های ساختارمند و غیرساختارمند را فراهم می‌کند. این داده‌ها می‌توانند شامل موارد زیر باشند:

- فایل‌ها: اسناد PDF، Word، صفحات Excel.
- پایگاه‌های داده: سیستم‌های SQL (مانند MySQL و PostgreSQL) و NoSQL (مانند MongoDB).
- ابزارهای همکاری: ادغام با ابزارهایی مانند Notion و Slack برای بازیابی و پردازش اطلاعات.
- وب‌سایت‌ها: استخراج داده از صفحات وب و منابع آنلاین.

این ابزارها داده‌ها را به شکلی پردازش می‌کنند که به راحتی برای مدل‌های زبان قابل استفاده باشند.

۲. ایندکس‌های سفارشی (Custom Indexing)

ایندکس‌ها هسته اصلی LlamaIndex هستند و به مدل‌های زبان اجازه می‌دهند تا داده‌ها را به شکلی سازمان‌یافته و کارآمد پردازش کنند. انواع ایندکس‌ها:

- ایندکس‌های سلسله‌مراتبی (Hierarchical Indexes): مناسب برای داده‌هایی که ساختار سلسله‌مراتبی دارند، مانند داکیومنت‌های چندبخشی.
- ایندکس‌های گرافی[1]: برای نمایش و پردازش داده‌های متصل، مانند شبکه‌های اجتماعی یا روابط پیچیده بین داده‌ها.
- ایندکس‌های ساده (Keyword-Based): پردازش سریع داده‌ها با استفاده از کلیدواژه‌ها.

این ایندکس‌ها به کاربران کمک می‌کنند اطلاعات دقیق‌تر و مرتبط‌تری از داده‌های بزرگ استخراج کنند.

۳. ابزارهای پرس‌وجو (Query Tools)

این ابزارها امکان انجام پرس‌وجوهای پیچیده بر روی داده‌های ایندکس‌شده را فراهم می‌کنند. ویژگی‌ها:

- خلاصه‌سازی داده‌های بزرگ به نکات کلیدی.
- استخراج پاسخ به پرسش‌های خاص از منابع داده گسترده.
- تحلیل پیشرفته و شناسایی الگوهای موجود در داده‌ها.

۴. بازیابی اطلاعات (Retrieval)

LlamaIndex قابلیت بازیابی داده‌ها را از میان منابع ایندکس‌شده فراهم می‌کند. ویژگی‌های این ابزار شامل:

- جستجوی متنی پیشرفته.

[1] Graph Indexes

- تطبیق دقیق بین پرسش کاربر و محتوای داده.
- کاهش زمان جستجو با بهینه‌سازی ساختار ایندکس‌ها.

۵. ادغام با مدل‌های زبان بزرگ (LLM Integration)

این ابزار به‌طور بومی با مدل‌های محبوب اجرای مدل مانند OpenAI، Hugging Face، و Anthropic سازگار است. کاربران می‌توانند داده‌های خصوصی را مستقیماً به مدل متصل کنند و از توانایی‌های پیشرفته LLMها برای تحلیل و تولید محتوا استفاده کنند.

۶. ابزارهای پردازش و تحلیل (Processing & Analysis Tools)

LlamaIndex ابزارهایی برای آماده‌سازی داده‌ها ارائه می‌دهد، از موارد قابل انجام:

- پاک‌سازی و نرمال‌سازی داده‌ها.
- تقسیم داده‌ها به بخش‌های کوچک‌تر برای پردازش بهینه توسط مدل.
- ترکیب داده‌های پراکنده از منابع مختلف.

کاربردهای LlamaIndex

- سیستم‌های پرسش و پاسخ سازمانی: پاسخ‌دهی به سوالات مبتنی بر داده‌های داخلی.
- تحلیل داده‌ها: استخراج بینش‌های کلیدی از منابع داده حجیم.
- اتوماسیون فرآیندهای تجاری: یکپارچه‌سازی داده‌های سازمانی با ابزارهای هوش مصنوعی.
- ساخت ربات‌های چت پیشرفته: ترکیب داده‌های خصوصی با مدل‌های زبان برای تعاملات هوشمند.

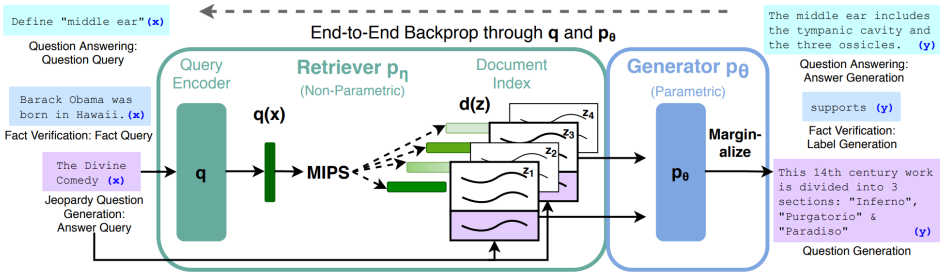
این ابزار بر مدیریت داده‌ها و ایجاد ایندکس‌های قدرتمند متمرکز است، در حالی که LangChain ابزارهایی برای مدیریت زنجیره‌ها و فرآیندهای چندمرحله‌ای ارائه می‌دهد. این دو چارچوب مکمل یکدیگر هستند و ترکیب آن‌ها امکان ساخت سیستم‌های هوش مصنوعی پیشرفته‌تر را فراهم می‌کند.

۲.۶ رویکردهای RAG

RAG یک روش پیشرفته در پردازش زبان است که از ترکیب دو نوع حافظه استفاده می‌کند: یکی حافظه پارامتری مثل مدل‌های زبانی از پیش‌آموزش‌دیده و دیگری حافظه غیرپارامتری مثل مجموعه‌ای از متون ذخیره‌شده (مثلاً ویکی‌پدیا). ابتدا مدل با استفاده از یک بخش بازیاب، متون مرتبط با ورودی را پیدا می‌کند. سپس این متون همراه با ورودی اصلی به تولیدکننده متن (مدل زبانی) ارسال می‌شوند تا پاسخ یا متن خروجی تولید شود. این مدل می‌تواند دانش خود را به‌روز کند و پاسخ‌هایی دقیق‌تر، متنوع‌تر و نزدیک به واقعیت ارائه دهد. نحوه کار RAG را در تصویر ۱.۶ شبیه سازی شده است. [۲]

۱.۲.۶ Vector Database RAG

RAG مبتنی بر پایگاه داده برداری یکی از روش‌های متداول در RAG سیستم‌ها است که از بردارهای معنایی برای نمایش متن‌ها و جستجوی مفهومی بهره می‌برد. این روش با تکیه بر تبدیل اسناد و پرسش‌ها به بردارهایی در فضای برداری، امکان بازیابی سریع و مرتبط اطلاعات از پایگاه‌های داده بزرگ را فراهم



شکل ۱.۶: شبیه سازی RAG پایه

می‌کند. فرایند کلی این نوع RAG شامل سه مرحله اصلی است: ایندکس‌گذاری، بازیابی، و تولید پاسخ. [۲۱] [۳۸]

در مرحله ایندکس‌گذاری، داده‌های خام به بخش‌های کوچک‌تر تقسیم شده و هر بخش با استفاده از مدل‌های embedding به بردار معنایی تبدیل می‌شود. این بردارها که معنا و زمینه متن را به صورت فشرده نمایش می‌دهند، در یک پایگاه داده برداری ذخیره می‌شوند. داده‌هایی مانند منبع متن، شماره صفحه، و تاریخ نیز برای بهبود دقت و فیلتر کردن نتایج در این پایگاه ذخیره می‌شوند.

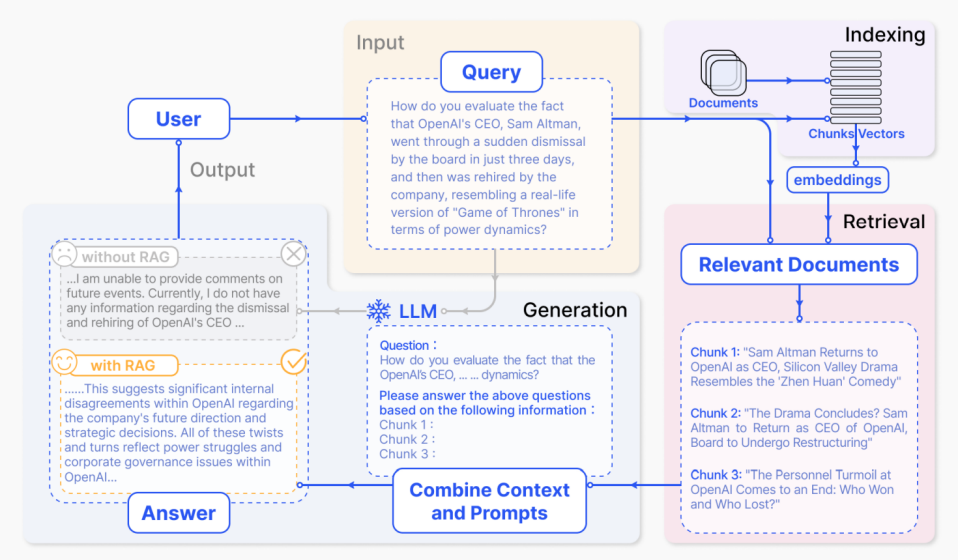
بازیابی در RAG برداری با تطبیق پرسش کاربر با بردارهای ذخیره‌شده در پایگاه داده انجام می‌شود. ابتدا پرسش کاربر با همان مدل embedding به بردار تبدیل می‌شود. سپس پایگاه داده برداری نزدیک‌ترین بردارهای مرتبط را بر اساس معیارهای شباهت معنایی مانند شباهت کسینوسی جستجو می‌کند. چانک‌های متنی که بالاترین امتیاز شباهت را دارند، به عنوان نتایج بازیابی‌شده انتخاب می‌شوند و آماده ارائه به مدل زبانی بزرگ می‌گردند.

در مرحله نهایی، یعنی تولید پاسخ، پرسش و بخش‌های بازیابی‌شده ترکیب شده و به صورت یک پرامپت به مدل زبانی بزرگ ارسال می‌شوند. مدل با تحلیل این پرامپت، پاسخی منسجم و مبتنی بر اطلاعات بازیابی‌شده تولید می‌کند. این پاسخ می‌تواند هم دقیق باشد و هم با زمینه معنایی پرسش مطابقت داشته باشد، زیرا از داده‌های خارجی برای تولید آن استفاده شده است. در تصویر ۲.۶ مراحل اجرا توصیف شده است.

مزیت‌های RAG برداری شامل سرعت بالا، انعطاف‌پذیری در جستجوی مفهومی، و سازگاری با انواع داده‌های متنی است. این سیستم‌ها می‌توانند حتی در صورت عدم تطابق دقیق کلمه‌به‌کلمه بین پرسش و متن‌های موجود، اطلاعات مرتبط را بازیابی کنند. همچنین، پایگاه داده برداری امکان مدیریت حجم زیادی از داده‌ها را با کارایی بالا فراهم می‌کند.

با این حال، این روش محدودیت‌هایی نیز دارد. از جمله این محدودیت‌ها می‌توان به ناتوانی در درک روابط پیچیده بین موجودیت‌ها و ضعف در پاسخ به سوالات چندمرحله‌ای اشاره کرد. همچنین، هزینه‌های ذخیره‌سازی و محاسبات مرتبط با بردارها در پایگاه‌های داده بزرگ ممکن است چالش‌برانگیز باشد. برای غلبه بر این محدودیت‌ها، بهبودهایی مانند بهینه‌سازی استراتژی‌های ایندکس‌گذاری، استفاده از فرادادها، و تکنیک‌های پیش‌بازیابی و پس‌بازیابی پیشنهاد شده است.

RAG مبتنی بر پایگاه داده برداری در کاربردهای متنوعی مانند چت‌بات‌ها، تحلیل اسناد علمی، و مدیریت دانش در سازمان‌ها استفاده می‌شود. این روش با فراهم کردن بازیابی سریع و مرتبط اطلاعات، به کاربران کمک می‌کند تا به پاسخ‌های دقیق و معنادار دست یابند. اگر چه محدودیت‌هایی دارد، اما همچنان یکی از روش‌های محبوب و موثر در سیستم‌های بازیابی اطلاعات و تولید متن به شمار می‌آید.



شکل ۲.۶: روند اجرا و استفاده از Vector Database RAG

۲.۲.۶ Graph RAG

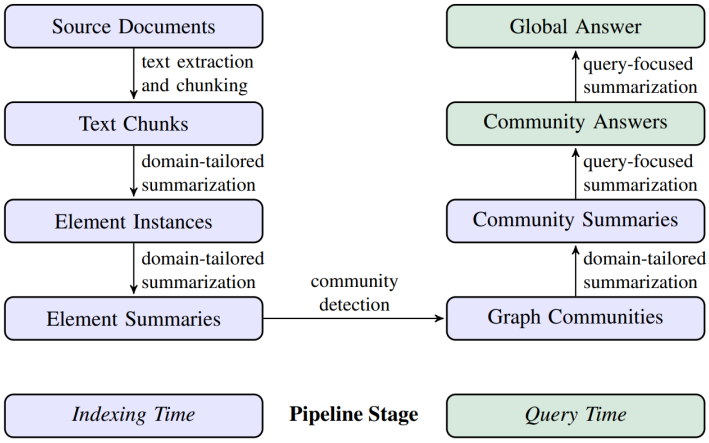
Graph RAG یکی از رویکردهای پیشرفته در سیستم‌ها RAG است که از گراف‌ها به عنوان ابزار اصلی برای نمایش روابط پیچیده میان موجودیت‌ها و مفاهیم استفاده می‌کند. روند اجرای این روش در تصویر ۳.۶ توصیف شده است. [۳]

Graph RAG بر اساس ایده استفاده از ساختارهای گرافی برای نمایش روابط میان موجودیت‌ها در مجموعه داده‌های متنی توسعه یافته است. گراف‌ها قادر به نمایش ارتباطات و وابستگی‌های پیچیده میان عناصر مختلف هستند، چیزی که در روش ۱.۲.۶ کمتر مورد توجه قرار می‌گیرد. با استفاده از گراف، سیستم می‌تواند نه تنها اطلاعات مرتبط را بازیابی کند، بلکه روابط میان این اطلاعات را نیز در نظر بگیرد، که این امر در پاسخ به پرسش‌های چندوجهی و پیچیده اهمیت بالایی دارد.

در رویکرد Graph RAG، ابتدا داده‌های متنی به قطعات کوچک‌تر تقسیم می‌شوند و سپس این قطعات برای استخراج موجودیت‌ها (مانند اشخاص، مکان‌ها یا مفاهیم) و روابط میان آن‌ها مورد تجزیه‌وتحلیل قرار می‌گیرند. این موجودیت‌ها و روابط در قالب گراف نمایش داده می‌شوند، که هر گره نشان‌دهنده یک موجودیت و هر یال نمایانگر رابطه میان موجودیت‌ها است. برای اطمینان از کیفیت و دقت گراف، از تکنیک‌های خلاصه‌سازی و حذف افزونگی استفاده می‌شود تا داده‌ها بهینه‌سازی شوند.

یکی از ویژگی‌های کلیدی Graph RAG استفاده از الگوریتم‌های شناسایی اجتماعات گرافی مانند الگوریتم لیدن است. این الگوریتم‌ها گراف را به بخش‌هایی تقسیم می‌کنند که هر بخش شامل موجودیت‌ها و روابط به‌هم‌پیوسته است (تصویر ۴.۶). سپس برای هر بخش خلاصه‌ای تولید می‌شود که دیدگاهی جامع از اطلاعات موجود در آن بخش ارائه می‌دهد. این خلاصه‌ها به سیستم اجازه می‌دهد تا در زمان پاسخگویی به پرسش‌های کاربر، به سرعت بخش‌های مرتبط را پیدا کند.

Graph RAG از خلاصه‌های گرافی برای تولید پاسخ‌های جامع و متناسب با پرسش‌های کاربران استفاده می‌کند. این سیستم ابتدا هر اجتماع گرافی را به صورت مستقل تحلیل می‌کند و پاسخ‌هایی جزئی تولید می‌کند. سپس این پاسخ‌های جزئی به یک پاسخ کلی ترکیب می‌شوند که نمایانگر دیدگاهی جامع



شکل ۳.۶: روند اجرا و استفاده از Graph RAG

و مرتبط با پرسش اصلی است. این فرآیند به ویژه در پاسخ‌گویی به پرسش‌هایی که نیازمند جمع‌آوری و تلفیق اطلاعات از منابع مختلف هستند، کاربرد دارد.

Graph RAG در مقایسه با روش ۱.۲.۶، دقت و جامعیت بالاتری در پاسخ‌گویی به پرسش‌های پیچیده ارائه می‌دهد. همچنین، استفاده از ساختار گرافی امکان تحلیل بهتر روابط میان داده‌ها را فراهم می‌کند. با این حال، ایجاد و مدیریت گراف‌های بزرگ ممکن است هزینه‌های محاسباتی بیشتری به همراه داشته باشد، و همچنین نیازمند طراحی دقیق برای به‌روزرسانی و مدیریت اطلاعات جدید است.

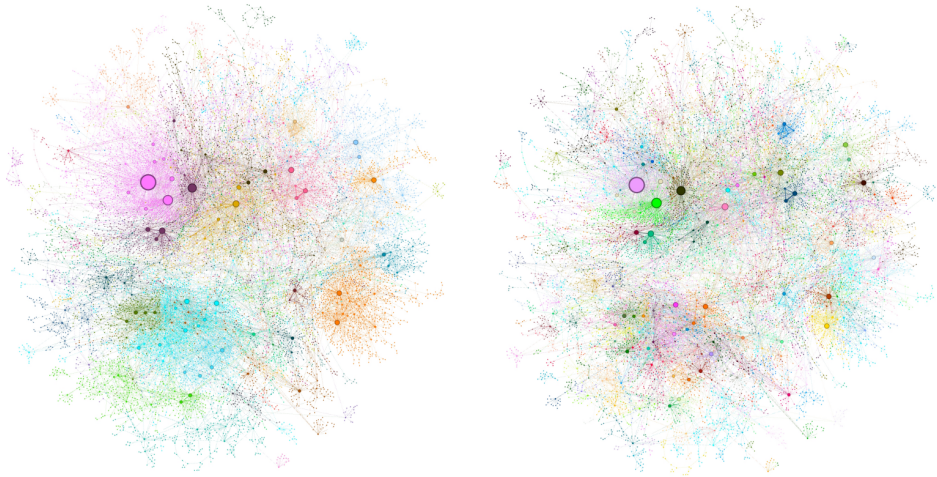
۳.۲.۶ Light RAG

LightRAG یک چارچوب پیشرفته در حوزه تولید تقویت‌شده با بازیابی RAG است که با استفاده از ساختارهای گرافی و روش‌های بازیابی دو سطحی، محدودیت‌های موجود در سیستم‌های قبلی را برطرف می‌کند. این رویکرد بهینه‌سازی شده، بازیابی اطلاعات را کارآمدتر، دقیق‌تر و انعطاف‌پذیرتر می‌سازد و نیازهای متنوع کاربران را پاسخ می‌دهد. روند کار LightRAG در تصویر ۵.۶ تصویر سازی شده است.

یکی ویژگی‌های LightRAG، استفاده از گراف‌های دانش مانند روش ۲.۲.۶ برای سازماندهی و مدیریت اطلاعات است. در این روش، اسناد به بخش‌های کوچک‌تری تقسیم می‌شوند و با استفاده از مدل‌های زبانی بزرگ، موجودیت‌ها، روابط و اطلاعات مرتبط استخراج می‌شوند. این عناصر در قالب یک گراف ساختاریافته ذخیره می‌شوند، به‌طوری که گره‌ها نمایانگر موجودیت‌ها و یال‌ها نشان‌دهنده روابط بین آن‌ها هستند. فرایند حذف داده‌های تکراری نیز برای بهینه‌سازی اندازه و عملکرد گراف اجرا می‌شود. این روش امکان تحلیل روابط پیچیده و بازیابی اطلاعات چندمنبعی را فراهم می‌کند.

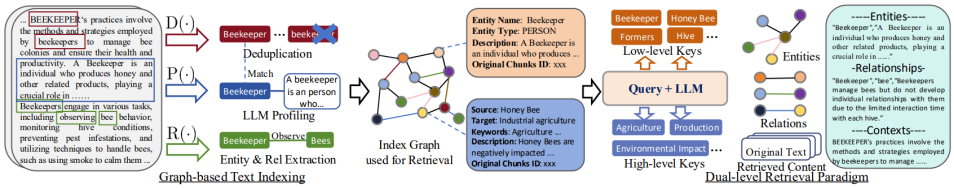
LightRAG از یک روش بازیابی دو سطحی استفاده می‌کند که هم به سوالات جزئی و هم به سوالات کلی پاسخ می‌دهد.

- بازیابی سطح پایین: این سطح به بازیابی دقیق اطلاعات درباره موجودیت‌ها و روابط خاص می‌پردازد. برای مثال، سوالاتی مانند «چه کسی نویسنده کتاب غرور و تعصب است؟» در این سطح پاسخ داده می‌شود. بازیابی سطح بالا: این سطح بر استخراج اطلاعات کلی‌تر و موضوعات گسترده‌تر تمرکز دارد و برای پاسخ‌گویی به سوالاتی مانند «هوش مصنوعی چگونه بر آموزش مدرن تأثیر می‌گذارد؟» مناسب است.



(a) Root communities at level 0 (b) Sub-communities at level 1

شکل ۴.۶: تقسیم گراف به بخش‌هایی مختلف



شکل ۵.۶: تقسیم گراف به بخش‌هایی مختلف

- بازیابی سطح بالا: این سطح بر استخراج اطلاعات کلی‌تر و موضوعات گسترده‌تر تمرکز دارد و برای پاسخ‌گویی به سوالاتی مانند «هوش مصنوعی چگونه بر آموزش مدرن تأثیر می‌گذارد؟» مناسب است. این دو سطح با هم کار می‌کنند تا پاسخ‌های دقیق و جامع ارائه دهند.

LightRAG با ادغام ساختارهای گرافی و vector embeddings، یعنی ادغام روش‌های ۱.۲.۶ و ۲.۲.۶ بازیابی اطلاعات را بهینه می‌کند. کلیدواژه‌های محلی و کلی از پرسش استخراج می‌شوند و برای شناسایی موجودیت‌ها و روابط مرتبط به کار می‌روند. این روش نه تنها ارتباطات مستقیم، بلکه روابط چندلایه را نیز بازیابی می‌کند و کیفیت پاسخ‌ها را بهبود می‌بخشد.

یکی از ویژگی‌های برجسته LightRAG، قابلیت به‌روزرسانی سریع و تدریجی گراف دانش است. به جای بازسازی کامل گراف (ایراد اصلی روش ۲.۲.۶)، داده‌های جدید به ساختار موجود اضافه می‌شوند. این ویژگی باعث کاهش هزینه‌های پردازشی و حفظ یکپارچگی داده‌های قدیمی می‌شود. این رویکرد تضمین می‌کند که سیستم همیشه به‌روز و دقیق باقی بماند، حتی در محیط‌هایی که داده‌ها به‌طور مداوم تغییر می‌کنند.

مزایای کلیدی LightRAG عبارت است از:

- جامعیت بیشتر: ساختار گرافی به LightRAG امکان می‌دهد تا اطلاعات جامع و روابط میان‌متنی را استخراج کرده و پاسخ‌های عمیق‌تری ارائه دهد.
- کارایی بالا: با ترکیب گراف و بردارها، این سیستم سرعت پردازش را افزایش داده و هزینه‌ها را کاهش می‌دهد.
- انعطاف‌پذیری: قابلیت به‌روزرسانی تدریجی سیستم را به ابزاری مناسب برای محیط‌های پویا تبدیل کرده است.
- مقیاس‌پذیری: این سیستم برای کاربردهایی با حجم بالای داده‌ها مناسب است و در حوزه‌های مختلف مانند پزشکی، آموزش و مدیریت دانش قابل استفاده است.

LightRAG یک نوآوری مهم در حوزه RAG است که با ترکیب ساختارهای گرافی، بازیابی دو سطحی، و الگوریتم‌های به‌روزرسانی تدریجی، مشکلات سیستم‌های قبلی را حل کرده و کارایی و دقت را بهبود داده است. این سیستم برای کاربردهایی مانند تحلیل داده‌های پویا، پاسخ‌گویی به سوالات چندمنبعی، و مدیریت دانش در سازمان‌ها، راه‌حلی ایده‌آل ارائه می‌دهد. [۴]

۴.۲.۶ اعمال RAG روی مدل

در این پروژه از LightRAG استفاده می‌شود زیرا شامل هردو روش قبلی می‌شود و مشکلات روش‌های دیگر را بطور کامل حل کرده است. مقایسه این سه روش در جدول ۱.۶ قرار دارد.

ویژگی‌ها	Vector Database RAG	Graph RAG	text
ساختار داده	نمایش برداری از متن و ذخیره‌سازی در پایگاه داده برداری	گراف‌های دانش شامل گره‌ها (موجودیت‌ها) و یال‌ها (روابط)	گراف دانش سبک با روش‌های شاخص‌گذاری و بازیابی دو سطحی
روش بازیابی	جستجو بر اساس نزدیکی برداری (similarity search)	شناسایی موجودیت‌ها و روابط از طریق اجتماع‌های گرافی	بازیابی دو سطحی: بازیابی دقیق (سطح پایین) و موضوعی (سطح بالا)
مزایا	سرعت بالا در جستجو و قابلیت کار با داده‌های بزرگ	توانایی نمایش روابط پیچیده میان داده‌ها و ارائه خلاصه‌های چندسطحی	انعطاف‌پذیری بالا، به‌روزرسانی تدریجی، و هزینه محاسباتی پایین
محدودیت‌ها	مشکل در مدیریت روابط پیچیده و نیاز به به‌روزرسانی‌های مداوم	هزینه محاسباتی بالا و پیچیدگی در مدیریت گراف‌های بزرگ	وابستگی به گراف‌های کوچک‌تر و نیاز به طراحی دقیق شاخص‌گذاری
کاربردها	جستجوی دانش عمومی و بازیابی متون	تحلیل داده‌های پیچیده، چندمنبعی و چندموضوعی	کاربردهای سریع در محیط‌های پویا و داده‌های متغیر

جدول ۱.۶: تفاوت‌های Vector Database RAG، Graph RAG و Light RAG

(ارزیابی مدل و توضیحات تکمیلی)

۳.۶ رویکردهای Prompt engineering

در این بخش بررسی می‌کنیم که ورودی مدل چه تاثیری در پاسخ مدل دارد و چه روش‌های در این مورد استفاده می‌شود و کدام روش‌های در این پروژه مورد استفاده قرار می‌گیرد به همراه دلایل استفاده از آن.

تأثیر ورودی مدل بر دقت آن عمدتاً به نحوه ارائه اطلاعات و میزان تطابق ورودی‌ها با وظایف موردنظر بستگی دارد. در مدل‌ها ورودی‌ها می‌توانند شامل مثال‌های مرتبط با وظیفه باشند که به مدل کمک می‌کنند وظیفه را بهتر درک کرده و پیش‌بینی کند. در یادگیری Zero-Shot، مدل تنها با یک توضیح متنی وظیفه را انجام می‌دهد که چالش‌برانگیز است اما انعطاف بالایی دارد. با اضافه کردن یک یا چند مثال (یادگیری One-Shot و Few-Shot)، مدل عملکرد بهتری از خود نشان می‌دهد، زیرا مثال‌ها به عنوان راهنمایی برای درک وظیفه عمل می‌کنند. این رویکردها نشان می‌دهند که دقت مدل به تعداد و کیفیت ورودی‌های ارائه‌شده وابسته است. [۵] [۶] اما در این پروژه به این دلیل که سوالات فرم و قالب مشخصی ندارند این روش قابل استفاده نیست.

علاوه بر این، اندازه مدل و مجموعه داده‌های آموزشی نیز بر عملکرد آن تأثیر زیادی دارد. افزایش تعداد پارامترهای مدل و ارائه داده‌های متنوع و با کیفیت، توانایی مدل را در شناسایی الگوهای پیچیده و انجام وظایف متنوع افزایش می‌دهد. با این حال، کیفیت ورودی‌ها و ارتباط آن‌ها با وظیفه همچنان اهمیت دارد؛ داده‌های ناهماهنگ می‌توانند دقت مدل را کاهش دهند. بنابراین، ورودی‌های مناسب و طراحی‌شده با دقت، نقش کلیدی در بهبود عملکرد مدل‌های زبانی ایفا می‌کنند.

در ادامه روش‌های استدلالی را بررسی می‌کنیم که در مقالات بخش ۲ هم از این روش‌ها استفاده کرده اند.

CoT ۱.۳.۶

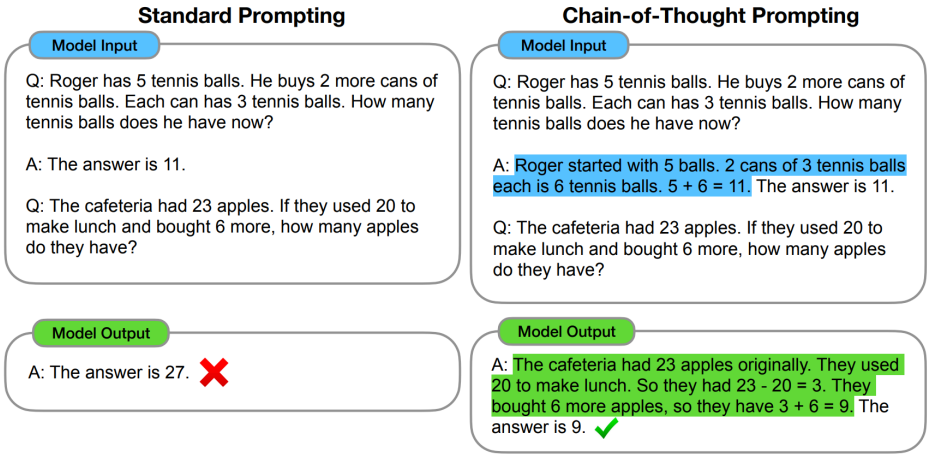
روش Chain-of-Thought Prompting یک تکنیک ساده اما قدرتمند برای بهبود توانایی استدلال مدل‌های زبانی بزرگ است. در این روش، به جای ارائه مستقیم سؤال و پاسخ، زنجیره‌ای از استدلال‌های میانی که منجر به پاسخ نهایی می‌شوند، به مدل ارائه می‌شود. این زنجیره‌ها به مدل کمک می‌کنند مسائل پیچیده را به مراحل ساده‌تر تقسیم کند و به طور گام‌به‌گام به پاسخ برسد. از مزایای این روش می‌توان به امکان تجزیه مسائل چندمرحله‌ای، ایجاد شفافیت در فرآیند استدلال و کاربرد آن در مسائل متنوعی مانند ریاضی، استدلال عقلانی و مسائل نمادین اشاره کرد. این روش به راحتی با چند نمونه‌ی آماده در مدل‌های بزرگ قابل پیاده‌سازی است و نیازی به آموزش‌های پیچیده ندارد. مثال استفاده از این روش در شکل ۶.۶.

آزمایش‌ها نشان داده‌اند که Chain-of-Thought Prompting در مدل‌های با ابعاد بسیار بزرگ (حدود ۱۰۰ میلیارد پارامتر یا بیشتر) عملکرد چشمگیری در حل مسائل پیچیده دارد. به عنوان مثال، این روش در مجموعه داده‌های ریاضی مانند GSM8K و مسائل استدلالی دیگر، باعث افزایش قابل‌توجه دقت مدل شده است. برخلاف روش‌های استاندارد که مدل‌ها را مستقیم به سمت پاسخ هدایت می‌کنند، این تکنیک از ارائه مراحل میانی استدلال بهره می‌برد که نه تنها عملکرد را بهبود می‌بخشد، بلکه فرآیند تصمیم‌گیری مدل را شفاف‌تر و قابل بررسی می‌کند. [۷]

sc-CoT ۲.۳.۶

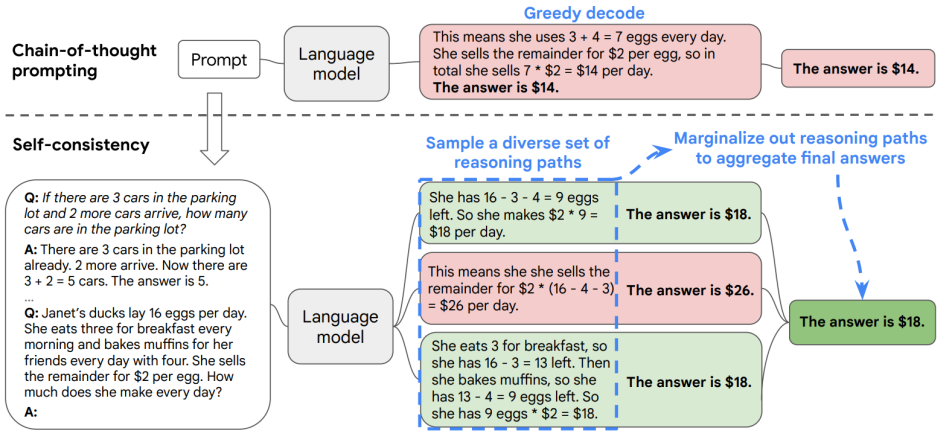
روش Self-Consistency، یک استراتژی جدید برای بهبود عملکرد روش زنجیره‌ای استدلال[۲] در مدل‌های زبانی است که هدف آن استفاده از تنوع مسیرهای استدلالی برای افزایش دقت در وظایف پیچیده است. به جای استفاده از استنتاج حریصانه[۳] برای انتخاب یک مسیر واحد، این روش مجموعه‌ای از مسیرهای استدلال متنوع را تولید کرده و پاسخ نهایی را با محاسبه میانگین این مسیرها مشخص می‌کند. فرضیه

[2] Chain-of-Thought Prompting
[3] greedy decoding



شکل ۶.۶: مقایسه ورودی CoT با ورودی عادی

اصلی این است که پاسخ درست معمولاً از چند مسیر مختلف به دست می‌آید و اجماع بین مسیرها می‌تواند نشان‌دهنده درستی پاسخ باشد. مشابه این روش با روش بخش ۱.۳.۶ در تصویر ۷.۶.

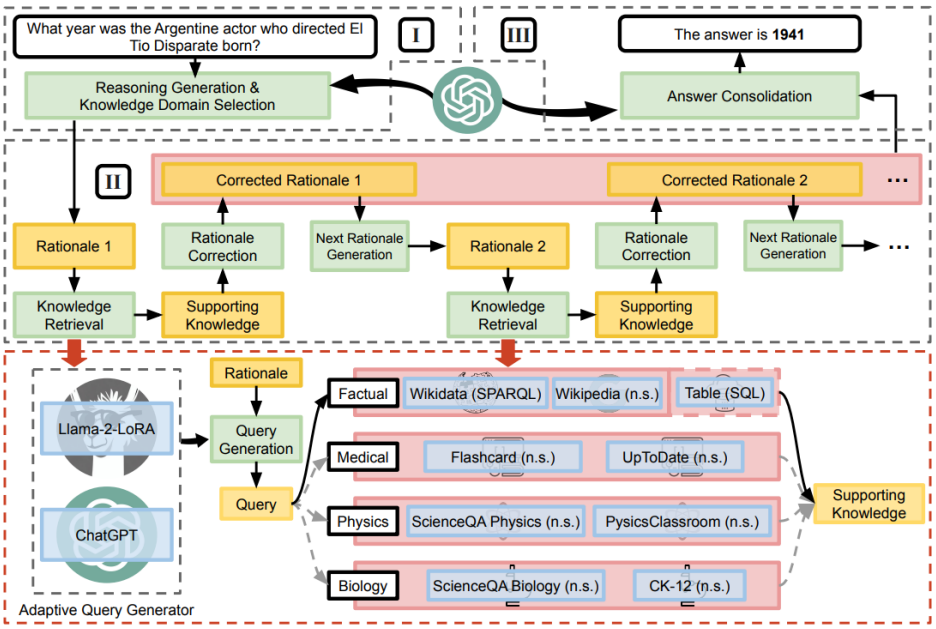


شکل ۷.۶: مقایسه روش CoT با روش sc-CoT

تفاوت اصلی بین Self-Consistency و Chain-of-Thought در نحوه پردازش پاسخ‌ها است. در حالی که روش زنجیره‌ای استدلال به یک مسیر مشخص متکی است، Self-Consistency مسیرهای مختلف را نمونه‌برداری کرده و پاسخ نهایی را بر اساس بیشترین توافق میان مسیرها تعیین می‌کند. این روش نیازی به آموزش اضافی یا داده‌های برچسب‌دار ندارد و می‌تواند بهبود چشمگیری در وظایف منطقی و ریاضی ایجاد کند. آزمایش‌ها نشان داده‌اند که Self-Consistency در مدل‌های زبانی بزرگ باعث بهبود دقت قابل توجهی می‌شود و در برخی موارد عملکرد بهتری نسبت به روش‌های مرسوم مثل beam search یا ensemble دارد. [۳۹]

CoK ۳.۳.۶

روش CoK[۴] یک چارچوب نوآورانه است که با استفاده از منابع مختلف دانش، عملکرد مدل‌های زبانی بزرگ را در وظایف دانش‌محور بهبود می‌دهد. این روش شامل سه مرحله اصلی است: آماده‌سازی استدلال برای شناسایی دامنه‌های دانش مرتبط، انطباق پویا با دانش که اطلاعات از منابع مختلف (ساختاریافته و غیرساختاریافته) بازیابی و استدلال‌ها اصلاح می‌شوند، و تجمیع پاسخ که پاسخ نهایی بر اساس استدلال‌های اصلاح‌شده تولید می‌شود. CoK به دلیل استفاده از اطلاعات خارجی و اصلاح تدریجی استدلال‌ها، میزان انتشار خطا را کاهش داده و دقت بیشتری در تولید پاسخ فراهم می‌کند. این روش در وظایف پیچیده مانند مسائل پزشکی و علمی، که نیاز به استفاده از دانش دقیق و به‌روز دارند، عملکرد برجسته‌ای داشته است. چارچوب این روش در تصویر ۸.۶. [۴۰]

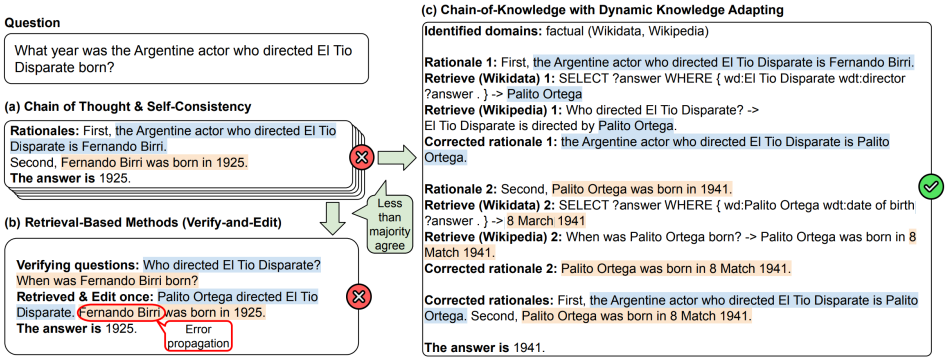


شکل ۸.۶: چارچوب زنجیره‌ای از دانش (CoK)، شامل (I) آماده‌سازی استدلال، (II) تطبیق دانش پویا، و (III) یکپارچه‌سازی پاسخ است.

در مقایسه، روش‌های CoT و sc-CoT بر تولید زنجیره‌های استدلال مبتنی بر دانش داخلی مدل تمرکز دارند. CoT استدلال‌ها را گام‌به‌گام ارائه می‌کند، اما بدون دسترسی به منابع خارجی، ممکن است اطلاعات نادرست تولید کند. Self-Consistency با تولید مسیرهای مختلف استدلال و انتخاب پاسخ با بیشترین اجماع، دقت بیشتری دارد، اما همچنان به دانش خارجی وابسته نیست. در مقابل، CoK با انطباق پویا و بازیابی اطلاعات از منابع خارجی، دقت و صحت بیشتری به‌ویژه در وظایف دانش‌محور ارائه می‌دهد و بر مشکلاتی مانند توهم مدل‌ها غلبه می‌کند. مقایسه این چند روش در تصویر ۹.۶.

این روش در صورت عدم استفاده از بخش ؟؟ روش مفیدی بود ولی در اینجا به دلیل استفاده از روش‌های پیشرفته RAG از این روش استفاده نمی‌کنیم.

[4] Chain-of-Knowledge



شکل ۹.۶: مقایسه روش CoT روش، sc-CoT و روش CoK

۴.۳.۶ ToT

روش ToT[۵] چارچوبی است که فرآیند استدلال مدل‌های زبانی را از یک زنجیره خطی (مانند ۱.۳.۶) به یک ساختار درختی گسترش می‌دهد. در این روش، مسئله به‌صورت یک درخت استدلال مدل‌سازی می‌شود که هر گره نمایانگر یک وضعیت جزئی و هر شاخه نشان‌دهنده یک گام استدلال است. مدل به جای انتخاب یک مسیر ثابت، می‌تواند چندین مسیر را به‌طور موازی کاوش کند، با استفاده از الگوریتم‌های جستجو مانند BFS[۶] یا DFS[۷]. این ساختار اجازه می‌دهد مدل به مسیرهای مختلف نگاه کرده، بازگشت کند و با ارزیابی گره‌ها، تصمیمات دقیق‌تری بگیرد. ToT برای وظایفی که نیاز به برنامه‌ریزی، خلاقیت یا استدلال‌های غیر بدیهی دارند، مانند حل معماهای ریاضی یا نوشتار خلاقانه، بسیار مؤثر بوده است. [۴۱]

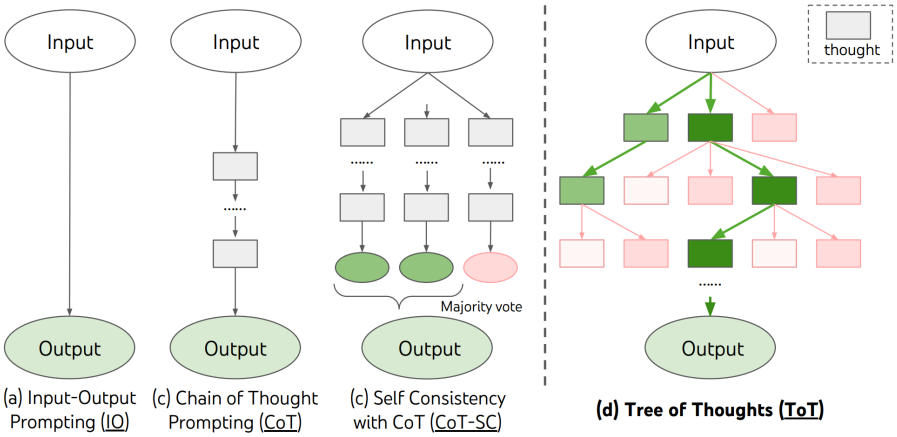
در مقایسه با CoT، که فقط یک زنجیره از استدلال‌ها را ارائه می‌دهد، ToT انعطاف‌پذیری بیشتری در کاوش مسیرهای جایگزین دارد و به دلیل ساختار درختی خود از جستجوی سیستمی بهره می‌برد. همچنین، در مقابل sc-CoT که از چندین زنجیره استدلال مستقل استفاده می‌کند و با اجماع پاسخ می‌دهد، ToT از جستجوهای هدایت‌شده با ارزیابی‌های لحظه‌ای برای انتخاب بهترین مسیر استفاده می‌کند. این باعث می‌شود ToT در وظایفی که نیاز به بررسی دقیق و کاوش مسیرهای مختلف دارند، عملکرد بسیار بهتری داشته باشد. مقایسه این روش‌ها در تصویر ۱۰.۶.

۵.۳.۶ اعمال Prompt engineering روی مدل

در این پروژه از روش ToT برای استدلال در مدل استفاده می‌کنیم چون طبق بررسی‌ها نسخه کامل‌تری از دو روش CoT و sc-CoT است.

(ارزیابی روش‌ها و انتخاب روش بهتر و اعمال روی مدل و ارزیابی)

[5] Tree of Thoughts
[6] Breadth-First Search
[7] Depth-First Search

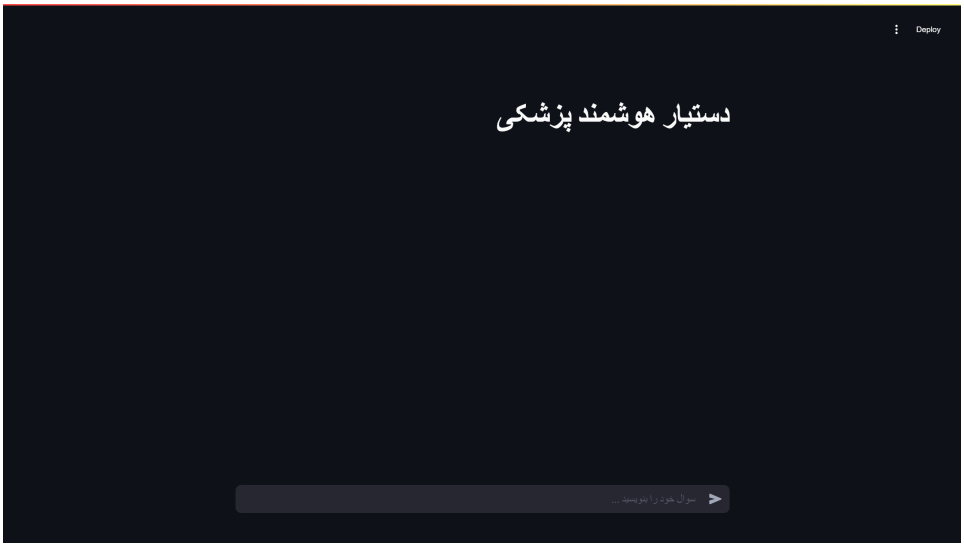


شکل ۱۰.۶: مقایسه روش CoT روش، sc-CoT و روش ToT

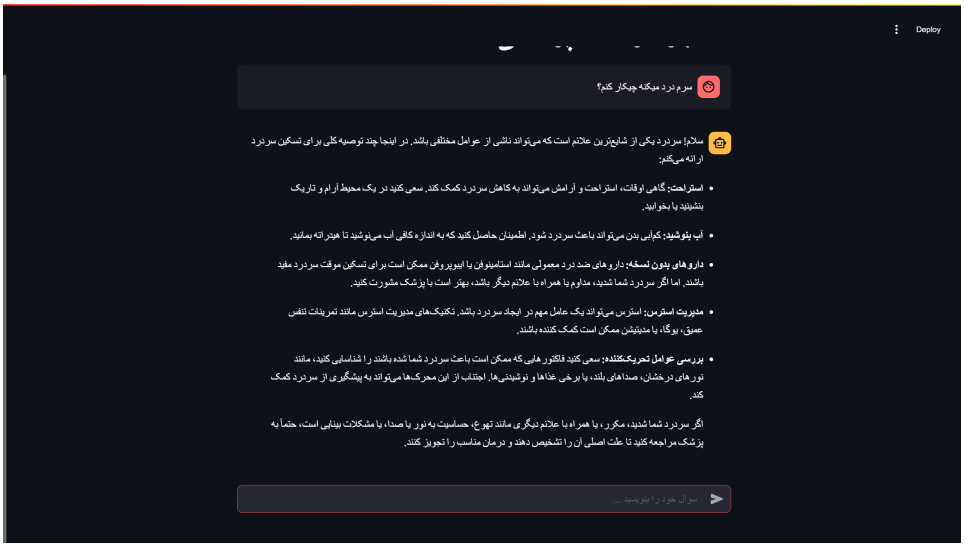
فصل ۷

رابط کاربری چت

در انتها یک رابط کاربری ساده برای تعامل با مدل با استفاده از پکیج StramLit ایجاد که طراحی کلی آن را در تصویر ۱.۷ و ۲.۷ قرار دارد.



شکل ۱.۷: رابط کاربری ایجاد شده برای تعامل با مدل (تصویر خالی)



شکل ۲.۷: رابط کاربری ایجاد شده برای تعامل با مدل (تصویر همراه با چت)

فصل ۸

کارهای بیشتر

۱.۸ مبدل صوت به متن (ASR)

۲.۸ مبدل متن به صوت (TTS)

۳.۸ مدل‌های (VLM)

۴.۸ Instruction tuning

۵.۸ آموزش کامل مدل (Pre-training)

فصل ۹

نتیجه گیری

(جدول کامل مقایسه با مدل‌های فارسی زبان و ارتقاهای هرقسمت)

مراجع

[1] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need."

[2] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, "Retrieval-augmented generation for knowledge-intensive NLP tasks."

[3] D. Edge, H. Trinh, N. Cheng, J. Bradley, A. Chao, A. Mody, S. Truitt, and J. Larson, "From local to global: A graph RAG approach to query-focused summarization."

[4] Z. Guo, L. Xia, Y. Yu, T. Ao, and C. Huang, "LightRAG: Simple and fast retrieval-augmented generation."

[5] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, and D. Amodei, "Language models are few-shot learners."

[6] J. Wang, E. Shi, S. Yu, Z. Wu, C. Ma, H. Dai, Q. Yang, Y. Kang, J. Wu, H. Hu, C. Yue, H. Zhang, Y. Liu, Y. Pan, Z. Liu, L. Sun, X. Li, B. Ge, X. Jiang, D. Zhu, Y. Yuan, D. Shen, T. Liu, and S. Zhang, "Prompt engineering for healthcare: Methodologies and applications."

[7] J. Wei, X. Wang, D. Schuurmans, M. Bosma, B. Ichter, F. Xia, E. Chi, Q. Le, and D. Zhou, "Chain-of-thought prompting elicits reasoning in large language models."

[8] K. Singhal, S. Azizi, T. Tu, S. S. Mahdavi, J. Wei, H. W. Chung, N. Scales, A. Tanwani, H. Cole-Lewis, S. Pfohl, P. Payne, M. Seneviratne, P. Gamble, C. Kelly, N. Scharli, A. Chowdhery, P. Mansfield, B. A. y. Arcas, D. Webster, G. S. Corrado, Y. Matias, K. Chou, J. Gottweis, N. Tomasev, Y. Liu, A. Rajkomar, J. Barral, C. Semturs, A. Karthikesalingam, and V. Natarajan, "Large language models encode clinical knowledge."

[9] K. Singhal, T. Tu, J. Gottweis, R. Sayres, E. Wulczyn, L. Hou, K. Clark, S. Pfohl, H. Cole-Lewis, D. Neal, M. Schaekermann, A. Wang, M. Amin, S. Lachgar, P. Mansfield, S. Prakash, B. Green, E. Dominowska, B. A. y. Arcas, N. Tomasev, Y. Liu, R. Wong, C. Semturs, S. S. Mahdavi, J. Barral, D. Webster, G. S. Corrado, Y. Matias, S. Azizi, A. Karthikesalingam, and V. Natarajan, "Towards expert-level medical question answering with large language models."

[10] Z. Chen, A. H. Cano, A. Romanou, A. Bonnet, K. Matoba, F. Salvi, M. Pagliardini, S. Fan, A. Köpf, A. Mohtashami, A. Sallinen, A. Sakhaeirad, V. Swamy, I. Krawczuk, D. Bayazit, A. Marmet, S. Montariol, M.-A. Hartley, M. Jaggi, and A. Bosselut, "MEDITRON-70b: Scaling medical pretraining for large language models."

[11] Y. Labrak, A. Bazoge, E. Morin, P.-A. Gourraud, M. Rouvier, and R. Dufour, "BioMistral: A collection of open-source pretrained large language models for medical domains."

[12] A. K. Gururajan, E. Lopez-Cuena, J. Bayarri-Planas, A. Tormos, D. Hinjos, P. Bernabeu-Perez, A. Arias-Duart, P. A. Martin-Torres, L. Urcelay-Ganzabal, M. Gonzalez-Mallo, S. Alvarez-Napagao, E. Ayguadé-Parra, and U. C. D. Garcia-Gasulla, "Aloe: A family of fine-tuned open healthcare LLMs."

[13] H. Kim, H. Hwang, J. Lee, S. Park, D. Kim, T. Lee, C. Yoon, J. Sohn, D. Choi, and J. Kang, "Small language models learn enhanced reasoning skills from medical textbooks."

[14] K. Vishwanath, J. Stryker, A. Alyakin, D. A. Alber, and E. K. Oermann, "MedMobile: A mobile-sized language model with expert-level clinical capabilities."

[15] D. Vilares and C. Gómez-Rodríguez, "HEAD-QA: A healthcare dataset for complex reasoning."

[16] A. Pal, L. K. Umapathi, and M. Sankarasubbu, "MedMCQA : A large-scale multi-subject multi-choice dataset for medical domain question answering."

[17] D. Jin, E. Pan, N. Oufattole, W.-H. Weng, H. Fang, and P. Szolovits, "What disease does this patient have? a large-scale open domain question answering dataset from medical exams."

[18] D. Hendrycks, C. Burns, S. Basart, A. Zou, M. Mazeika, D. Song, and J. Steinhardt, "Measuring massive multitask language understanding."

[19] Q. Jin, B. Dhingra, Z. Liu, W. W. Cohen, and X. Lu, "PubMedQA: A dataset for biomedical research question answering."

[20] H. Chen, Z. Fang, Y. Singla, and M. Dredze, "Benchmarking large language models on answering and explaining challenging medical questions."

[21] G. Xiong, Q. Jin, Z. Lu, and A. Zhang, "Benchmarking retrieval-augmented generation for medicine."

[22] K. Zhang, S. Zeng, E. Hua, N. Ding, Z.-R. Chen, Z. Ma, H. Li, G. Cui, B. Qi, X. Zhu, X. Lv, H. Jinfang, Z. Liu, and B. Zhou, "UltraMedical: Building specialized generalists in biomedicine."

[23] I. Manes, N. Ronn, D. Cohen, R. I. Ber, Z. Horowitz-Kugler, and G. Stanovsky, "K-QA: A real-world medical q&a benchmark."

[24] V. Aryabumi, J. Dang, D. Talupuru, S. Dash, D. Cairuz, H. Lin, B. Venkitesh, M. Smith, J. A. Campos, Y. C. Tan, K. Marchisio, M. Bartolo, S. Ruder, A. Locatelli, J. Kreutzer, N. Frosst, A. Gomez, P. Blunsom, M. Fadaee, A. Üstün, and S. Hooker, "Aya 23: Open weight releases to further multilingual progress."

[25] J. Dang, S. Singh, D. D'souza, A. Ahmadian, A. Salamanca, M. Smith, A. Peppin, S. Hong, M. Govindassamy, T. Zhao, S. Kublik, M. Amer, V. Aryabumi, J. A. Campos, Y.-C. Tan, T. Kocmi, F. Strub, N. Grinsztajn, Y. Flet-Berliac, A. Locatelli, H. Lin, D. Talupuru, B. Venkitesh, D. Cairuz, B. Yang, T. Chung, W.-Y. Ko, S. S. Shi, A. Shukayev, S. Bae, A. Piktus, R. Castagné, F. Cruz-Salinas, E. Kim, L. Crawhall-Stein, A. Morisot, S. Roy, P. Blunsom, I. Zhang, A. Gomez, N. Frosst, M. Fadaee, B. Ermis, A. Üstün, and S. Hooker, "Aya expanse: Combining research breakthroughs for a new multilingual frontier."

[26] L. Gao, J. Tow, B. Abbasi, S. Biderman, S. Black, A. DiPofi, C. Foster, L. Golding, J. Hsu, A. Le Noac'h, H. Li, K. McDonell, N. Muennighoff, C. Ociepa, J. Phang, L. Reynolds, H. Schoelkopf, A. Skowron, L. Sutawika, E. Tang, A. Thite, B. Wang, K. Wang, and A. Zou, "A framework for few-shot language model evaluation," 07 2024.

[27] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, and Y. Artzi, "BERTScore: Evaluating text generation with BERT."

[28] F. Bao, M. Li, R. Luo, and O. Mendelevitch, "HHEM-2.1-Open," 2024.

[29] Y. Zheng, R. Zhang, J. Zhang, Y. Ye, Z. Luo, Z. Feng, and Y. Ma, "Llamafactory: Unified efficient fine-tuning of 100+ language models," in Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 3: System Demonstrations), (Bangkok, Thailand), Association for Computational Linguistics, 2024.

[30] X. Contributors, "Xtuner: A toolkit for efficiently fine-tuning llm." https://github.com/InternLM/xtuner, 2023.

[31] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "LoRA: Low-rank adaptation of large language models."

[32] T. Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer, "QLoRA: Efficient finetuning of quantized LLMs."

[33] C. Gao and S. Q. Zhang, "DLoRA: Distributed parameter-efficient fine-tuning solution for large language model."

[34] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, and R. Lowe, "Training language models to follow instructions with human feedback."

[35] R. Rafailov, A. Sharma, E. Mitchell, S. Ermon, C. D. Manning, and C. Finn, "Direct preference optimization: Your language model is secretly a reward model."

[36] K. Ethayarajh, W. Xu, N. Muennighoff, D. Jurafsky, and D. Kiela, "KTO: Model alignment as prospect theoretic optimization."

[37] J. Hong, N. Lee, and J. Thorne, "ORPO: Monolithic preference optimization without reference model."

[38] Y. Gao, Y. Xiong, X. Gao, K. Jia, J. Pan, Y. Bi, Y. Dai, J. Sun, M. Wang, and H. Wang, "Retrieval-augmented generation for large language models: A survey."

[39] X. Wang, J. Wei, D. Schuurmans, Q. Le, E. Chi, S. Narang, A. Chowdhery, and D. Zhou, "Self-consistency improves chain of thought reasoning in language models."

[40] X. Li, R. Zhao, Y. K. Chia, B. Ding, S. Joty, S. Poria, and L. Bing, "Chain-of-knowledge: Grounding large language models via dynamic knowledge adapting over heterogeneous sources."

[41] S. Yao, D. Yu, J. Zhao, I. Shafran, T. L. Griffiths, Y. Cao, and K. Narasimhan, "Tree of thoughts: Deliberate problem solving with large language models."